

ChartGenEval：節奏遊戲譜面生成的多維度指標套件

Jhen-Ke Lin

國立陽明交通大學

jacob.cs14@nycu.edu.tw

本文為英文版 (paper.tex, v6) 之中文對照；正式版本以英文版為準。

摘要

節奏遊戲譜面既要貼合音樂，也要玩起來良好；同一首歌卻可能容納多張合法譜面。製譜是設計，因此與單一官方譜面的一致度，會把合法替代與真正的缺陷一併懲罰。音符選擇的自由仍留下一項任何替代都無法迴避的要求：無論選了哪些音符，它們都必須站在歌曲的音樂時間上。時值是音樂貼合度的地板。我們提出 ChartGenEval，一套不把任何音符序列當成答案、直接測量這個地板的指標套件：它只取官方譜面的作者編定時值圖，從不使用其音符位置。其整譜格線相位偏移以零中位誤差回收注入的 15–60 ms 平移——而這些平移使所有主要只讀譜面輸出的變化都不超過人類譜標準差的 0.03 倍。

在地板之上，品質容許多種答案，因此 ChartGenEval 以分數 profile 取代單一排名：六個維度——時值、音符序列、重複與形式、音樂呼應、與同難度人類譜的距離，以及可玩性限制——各自評分、分開報告，不合成總分。受控損壞說明原因：向常見模式改寫使語言模型 perplexity 下降 37%，循環崩解使自相似度上升 62%。在 40 首歌發展組上選定的十個凍結損壞–測量檢驗，全數通過 80 個未接觸歌曲群組上的保留資料確認，32 項指定控制亦全數通過；計入一組代數耦合後，餘九個非冗餘檢驗。其餘本文提出的元件目前只有發展證據；以玩家評分為效標的效度仍待建立。施用於五個公開生成器後，套件揭露單一排名會掩蓋的時值與難度特定偏離。我們於 <https://github.com/JacobLinCool/ChartGenEval> 釋出實作、受控損壞、校準值與逐譜紀錄。

1 引言

節奏遊戲的自動譜面生成——把音訊映射為可遊玩的定時、定型音符序列——已從 onset 偵測管線進展到條件式序列模型 [1–4]。評估卻沒有跟上。譜面規定玩家何時做什麼：它同時對音樂與玩家負責。本文把評估組織為兩個問題。譜面是否貼合音樂——音符是否錨定在節拍上、其活動是否跟隨音樂起伏？譜面是否玩起來良好——是否提供可學習的 pattern 與帶變化的重複，其要求是否與指定難度相稱？譜面是設計作品而非標註：貼合容許多種答案，而這些答案玩起來如何，正是區分它們之處。

既有方法回答了有用但局部的問題。主流評估——與單一官方譜面比較的配置 F1——量化的是重建程度：合法替代會像缺陷一樣降低重合度，歌曲沒有參照譜時也無法比較。最佳化一致度因此獎勵複製官方答案，懲罰的正是讓製譜成為設計問題的那些出走。

語言模型 (LM) 似然量化模型適配度；分佈與自相似度統計描述生成材料；玩家或專家研究則建立系統層級的體驗。它們各自回答自己的問題，而其聚合分數的權衡關係並不透明。

把音符選擇留給創意的評估，仍必須守住一個地板。音符再自由，仍要對歌曲的音樂時間負責：音符偏離節拍的譜面，在談品質之前就已失格。時值因此是音樂貼合度的地板——任何合法替代都仍須滿足的必要條件。我們的第一步是把官方譜面的兩種角色拆開：只取其作者編定時值圖、從不使用其音符位置，讓音樂時間框架得以共享，框架內的音符選擇保持自由。本文提出的譜面對格線時值 profile 與整譜格線相位偏移，使這個地板不需參照音符序列即可檢驗；偏移搜尋回收了所有主要只讀譜面測量都錯過的 15–60 ms 注入平移。

站上地板的譜面還不是好譜面。在地板之上，品質有程度之分、也容許多種答案，因此 ChartGenEval 以分數 profile 取代單一排名：六個維度圍繞音樂貼合度與遊玩特性組織 (圖 1)。除時值外，套件追問：活動是否跟隨音樂 (兩項譜面–音訊呼應測量)、長程結構是否回返而不停滯 (ABAB 交互回應與停滯–疏離代理量)，以及譜面距同難度人類譜有多遠 (一個 32 維距離)。這些本文提出的元件，再與音符密度、音符間隔、轉移 pattern、4-gram 重複等既有譜面統計量結合，並轉換為同難度典型性分數或單側限制檢查；可玩性限制是它們自己的地板。所有維度分開報告，不定義通用總分。

受控損壞提供敏感度證據。我們從人類譜出發，加入三個強度、由構造保證存在的缺陷，檢查宣告測量是否惡化，同時要求指定控制保持不變。九種損壞涵蓋密集時值抖動、稀疏時值離群、整體時值平移、音符類型置換、循環崩解、常見模式改寫、音符率縮放、爆發插入與小節順序洗牌。發展實驗用於選擇與修訂候選測量；另行凍結的確認實驗，則在未接觸歌曲上評估十個宣告的損壞–測量檢驗。這個雙層設計把探索性的候選證據與保留資料上的確認分開。

三項發展結果說明各維度為何必須分開。LM perplexity 獎勵向常見模式改寫；自相似度獎勵循環崩解；所有主要只讀譜面輸出則都錯過固定的譜面–音訊平移。凍結確認中，十個宣告檢驗與 32 項指定控制全數通過 (§4.2)。

我們的貢獻如下：

1. 多維度指標套件。ChartGenEval 定義譜面對格線、譜面–音訊、本文所提的長程結構與人類譜距離測量，並結合既有譜面統計量的難度條件化




圖 1: 評估總覽。我們從人類譜出發，加入三個強度的單一已知缺陷，檢驗各 ChartGenEval 元件宣告的反應。只讀譜面的統計量以指定難度的人類譜為參照。時值使用配對官方譜面的作者編定時值圖，卻不使用其中的音符位置；音訊估計格線作為後備。六個維度分開報告，因為它們回答不同問題。

版本。每項輸出都有明定的解讀角色，並維持分開報告。

2. 譜面專用操作化。我們定義整譜格線相位偏移、小節層級密度-能量呼應、連打首音 onset 支持度、ABAB 交互回應、停滯-疏離結構代理量，以及 32 維、依難度條件化的人類譜差距。格線相位偏移納入保留資料確認，其餘五項本文提出的操作化目前具有發展證據。
3. 受控損壞證據。九種具劑量控制的損壞，同時檢驗目標反應與指定不變性，產生九個非冗餘的保留資料損壞-測量檢驗。相同實驗亦找出 perplexity、自相似度的符號反轉，以及只讀譜面指標對整體平移的盲點。
4. 系統層級應用與可重現材料。把相容元件施用於五個公開生成器，可定位時值、序列、密度與難度特定偏離。我們於 <https://github.com/JacobLinCool/ChartGenEval> 釋出實作、受控損壞、校準值與逐譜紀錄。

2 相關研究

參照譜一致度。DDC 與 GenéLive! 對預測音符位置報告 F-score，TCP 則報告 onset、onset-plus-type F1 與局部 pattern recall [1, 3, 4]。其容差與聚合方式各異：DDC 使用 ± 20 ms，GenéLive! 使用 ± 50 ms，TCP 則以小節比例定義容差。TaikoNation 改以 23 ms 二元 frame 與 pattern space 比較 [2]。這些都是重建估計量，承繼 §1 所述的單一參照限制。

無配對與人類錨定評估。DDC 把 LM perplexity 與 token accuracy 用作保留資料上的模型適配度，而非生成譜品質分數 [1]。符號音樂與文字生成研究則提供多樣性、特徵分佈、自相似度與集合層級重複統計 [5–9]。人類研究回答另一個問題：MuTE 以專家評分驗證參照對齊的鋼琴編曲測量 [10]；GenéLive! 報告專業譜師的部署回饋 [3]；Mania Archetype 則結合參照相似度與八位資深玩家評分 [11]。ChartGenEval 提供這類人類研究可據以開展的自動測量與損壞敏感度證據。

指標壓力測試與時值。SCHmUBERT 建構非音樂性的 piano roll，卻能匹配逐 frame 自相似統計 [12]。Fréchet Music Distance 以音高與力度擾動測試，但仍是集合層級的 embedding 距離 [13]。STRUM 在逐歌搜尋整體偏移後報告參照 onset F1 [14]；ChartGenEval 則把整譜格線相位偏移作為譜面層級測量，且不以參照音符作為目標。我們的 6 ms deadzone 以時間辨別研究為依據 [15, 16] (§3.4)。

3 方法

3.1 ChartGenEval 指標套件

ChartGenEval 把 profile 建構與損壞敏感度測試分開。套件先定義每項測量的構念、輸入、輸出與解讀角色，再以受控損壞檢驗其宣告反應。表 1 列出哪些測量由本文提出、哪些改編自既有譜面統計量，以及本研究對各項測量所提供的最高證據層級。

本文提出的測量，針對單一譜面統計量留下的缺口設計。整譜格線相位偏移在固定的小節、拍與八分音符錨點上，搜尋 -250 至 $+250$ ms 的平移量。為檢驗活動是否跟隨音樂起伏，密度-能量呼應是在作者編定的小節視窗內，計算每秒打擊數與線性 mel 能量的 Spearman 相關。可用視窗少於八個，或歌曲能量的第 90 與第 10 百分位差小於其中位數的 5% 時，這項測量記為不可用。連打首音 onset 支持度是節奏群首中，在三個 mel frames (約 ± 35 ms) 內的最大 spectral flux 達到該歌曲第 60 百分位門檻者所占比例。相鄰 onset 的間隔至少為 0.25 s 時才開始新群組，以免密集連打主導分母。

對長程結構而言，交互回應把譜面依十六分音符位置切成兩小節樂句。具 ± 1 個位置容差、經機率校正的節奏相似度，乘上經機率校正的音色一致度。若 $S(i, j)$ 表示這個乘積，分數就是 $S(i, i+2)[1 - S(i, i+1)]$ 的樂句平均：素材隔著中間樂句回返，但相鄰的 copy-paste 重複不會得到獎勵。

停滯-疏離代理量使用活動小節的節奏與音色 fingerprints。若某小節是連續相似度 $\geq .8$ 序列中的第四個或之後成員，或其每個可用的 16 音符音色視窗都呈現週期不超過四的精確循環，便標為停滯。若前後

構念	主要輸出與解讀	來源	證據層級
時值	格線容差內比例與殘差尾部；整譜格線相位偏移	本文提出的譜面對格線 profile	C1、C1s、C2 確認
音符序列	LM loss 作為描述；未見轉移懲罰作為單側熟悉度檢查	改編的 n -gram 統計	C3 確認（轉移熟悉度）
重複與形式	4-gram 典型性；ABAB 交互回應；停滯-疏離代理量 (boredom_v2)	改編的 4-gram 分數；兩項本文提出的操作化	C4、C5、C8 確認（單一 4-gram 軸）；新測量僅有發展證據
音樂呼應	小節層級密度-能量等級相關；連打首音 onset 支持度	兩項本文提出的操作化	僅有發展證據
人類譜距離	32 維譜面表徵中，到 20 張最近訓練譜的平均距離	本文提出的譜面專用實例	僅有發展證據
難度與限制	密度與負荷典型性；過載與密度尖峰限制	改編統計量；本文提出的校準	C6、C7 確認（密度典型性、尖峰限制）

表 1: ChartGenEval 的構念、來源與證據邊界。各構念所需的時值、音訊、格線或參照錨點，見方法一節 (§3.2、§3.3)。「本文提出」表示操作化由本文界定，不代表其中每個基礎統計量都是新的。「確認」只指具名的凍結輸出。僅有發展證據的操作化是在 40 首歌的發展組上選擇與修訂，未納入凍結主要檢驗。任何證據層級都不代表已建立以玩家評分為效標的效度。

32 小節內都沒有相似度至少 .75 的小節，便標為疏離。原始輸出是兩類集合聯集占有活動小節的比例。刻意採用這個操作性名稱，是因為測量描述的是譜面結構，尚未驗證為玩家感受到的無聊。最後，人類譜差距以 32 個音符間隔、音符類型、密度與多樣性特徵表示每張譜；特徵依難度標準化，原始差距 g 是到同難度 20 張最近訓練譜的平均歐氏距離。有界的顯示分數為 $\exp(-g/a)$ ，其中 a 是該 course leave-one-out 差距的第 90 百分位。表徵本身為譜面專用，其中的 entropy、bigram 與最近鄰基礎量則是既有統計方法。

3.2 資料與時值參照

我們使用自網路社群資源蒐集的 taiko 風格譜面檔與對應音訊；譜面檔轉錄官方難度 course，作為人類參照譜。由於譜面與音訊屬潛在受版權保護的內容，語料本身不隨本文發布：釋出物承載衍生的校準統計與逐譜紀錄，分析則固定於單一語料快照，其雜湊由凍結 manifest 釘住。來源紀錄依穩定的群組識別碼與音訊 SHA-256 合併為歌曲群組；對映不一致時拒絕納入。訓練集包含 924 筆來源紀錄、813 個歌曲群組與 3,880 張各難度譜面，用於擬合校準值與 LM。測試集的 140 筆來源紀錄合併為依儲存順序排列的 120 個歌曲群組。前 40 組包含各可得難度的 170 張人類譜，構成指標與損壞設計、圖表及系統 profile 使用的發展組。其餘索引 [40, 120) 構成 80 首歌的確認組；直到下述協定、實作、校準、執行環境與分析契約全數凍結後，才開啟這批資料。

五項僅有發展證據的本文所提元件，依一份在其選擇與修訂後才寫成的規格整理，因此其分析維持探索性。釋出紀錄以雜湊把每項結果綁定到其確切輸入。

時值需要外部的歌曲時值參照。主要格線使用配對官方譜面檔中，由作者編定的逐小節時間戳、拍號與速度中繼資料；官方譜面的音符時間與類型從不作為目標。換言之，官方檔案提供的是時值圖，不是唯一正確的音符序列。這保留時值圖中精確的小節結構，也讓生成譜能在同一音樂時間框架內採取不同而合法的音符設計。我們絕不使用生成譜自行宣告的格線，否則生成器便能定義自己的參照。

缺少作者編定時值圖時，一般 profile 可改用音訊估計的 downbeat。40 首發展歌曲中，有 39 首的估計節

拍週期與中繼資料週期相差不超過 2%；其餘一首相差 2.39%。兩種來源對第一拍仍可能不一致，所以下述格線相位偏移搜尋刻意容許這項模糊。絕對偏移仍以作者編定格線報告，因為音訊必須自行推估小節相位。凍結確認只使用各 course 的作者編定時值圖；若缺失，受影響的時值測量記為不可用，不以音訊估計格線代替。

3.3 測量角色與難度校準

每張譜都是定時、定型的音符序列。我們依圖 1 的六個問題組安排原始測量，並分屬 §1 的兩項要求。音樂貼合度是所聽與所打的一致，因此時值與音樂呼應需要歌曲；其餘四組不需要音訊，用來描述遊玩特性，其中本文提出的結構測量另需節拍格線。改編的譜面內部基礎量包括平滑化 trigram LM、未見轉移率、音符率、局部密度、短間隔負荷、entropy，以及獨特或重複的 4-grams。我們保留 LM loss 作為模型適配度描述。讀作平均逐音符資訊量時，同一個量稱為 *pattern-IC*；其同難度範圍分數僅作為次要分析。釋出名稱 *transition_validity_score* 的解讀則收斂為「轉移熟悉度」：訓練語料中未曾出現的 trigram，不一定是無效轉移。本文提出的結構、音訊呼應、時值與人類譜差距測量已在 §3.1 定義。

我們把選定的 band-calibrated 特徵轉成同難度範圍分數。對每個 course 與選定特徵，令 l, u 分別為訓練譜的第 10、90 百分位， $h = \max((u-l)/2, 10^{-9})$ 為受保護的半範圍寬。兩側使用同一尺度：

$$d(x) = \begin{cases} (l-x)/h, & x < l, \\ 0, & l \leq x \leq u, \\ (x-u)/h, & x > u, \end{cases} \quad (1)$$

$$s(x) = \frac{1}{1 + d(x)^2}.$$

因此範圍內得 1，向下與向上等距偏離得到相同分數。我們同時保留帶號距離，使大幅偏離不會塌縮到同一個近零分數。

這個分數量的是譜對指定難度而言有多不尋常；它本身不說譜好不好。有些測量有宣告的不可欲方向，例如超出難度相對限制的過度負荷；它們使用另行具名的單側分數。轉移熟悉度相對訓練語料同樣是單側

的，但不意味語義上無效。沒有宣告校準的 family 測量保留為 raw 描述。entropy、密度、重複則可過低也可過高。受控損壞只支持單向推論——已知損壞傾向把這些值推出人類範圍。一張不尋常但仍可玩、仍跟著音樂的譜可能是創意 (§5)。

我們依各結果宣告的角色與證據層級加以使用。可玩性限制維持分開的地板檢查；發展組的人類譜中，音符率、短間隔與密度尖峰檢查分別有 88%、89% 與 97% 得分至少 0.99。整體平移估計等數值則維持描述性。公開介面分開回傳具名測量與檢查。

3.4 對歌曲測量時值

依已發表的短間隔恰可覺差 [15]，我們以 6 ms 作為 deadzone。這項結果提供格線對齊容差的動機，不同於已在本語料玩家上驗證的 gameplay 閾值。更大的誤差按三個範圍報告：超過 6、12、18 ms。相鄰音符間隔另以 $\max(6\text{ ms}, 2.5\% \times \text{IOI})$ 的容差比較。每個音符被計為容差內、超過三個範圍之一、或未配對。未配對音符留在分母中，因此新增的離格音符會降低容差內比率；此量沒有參照音符 recall 項，因此刪除未配對的生成音符可能提高比率。我們把它與音符數、同難度密度一併解讀。我們先對每張譜摘要，再跨譜報告中位數與尾部。

最近格點配對可能錯過恆定平移（圖 2）：在密格線上，每個被平移的音符可能只是與另一個鄰近格點配對。因此我們對整張譜估計單一偏移：對 -250 至 +250 ms 間的每個候選，測量多少音符與參照小節內的固定細分對齊，選出一致性最強的偏移。作者編定格線的小節來自官方譜面的時值圖，而非其音符序列；音訊估計格線的小節則由音訊 downbeat 推估。合併小節、拍、八分音符細分可消解多數週期性平手；殘餘平手取最小幅度偏移。在正式 protocol 中，兩種時值摘要都必須有上述其中一種外部格線；作者編定時值圖與音訊估計格線皆不可得時，時值結果記為不可用。BPM 只給週期、不給 phase，因此不足以作為時值參照。

3.5 受控損壞與驗收規則

development 反應矩陣屬探索性分析。它在 170 張 development 譜上報告最大劑量的標準化變化與逐譜淨方向——相對各自原譜上升的比例減下降比例。這些譜不作為彼此獨立的推論單位；矩陣沒有 chance band，也不宣稱 cell 層級顯著性。raw 特徵與其衍生分數在同一批變體上計算；等價量不計為獨立佐證，並另報與音符數的關聯。development 的 C5 檢查由一個 LM 選擇常見模式改寫、另一個 LM 評分；perplexity 反轉仍在。

凍結 **confirmation**。表 2 的十個主要檢驗在凍結前未接觸的 80-song panel 上評估。每個非零 corruption cell 與每個 control condition 使用固定的五個 base seeds：1103、2207、3301、4409、5519。replicates 先在每張譜、每個 dose 內取平均。把所有測量定向為越大越好後，第一個統計量是原譜加三個凍結 severity 與測量間的逐譜 Spearman 相關；若四個反應全為常數，事前定義為零敏感度。第二個統計量是定向後的最大劑量值減去該 pair 的固定 scoped sham。course 只有在原譜值、全部 target doses 與 replicates、sham 及必要 controls 皆可得時才算完整。歌曲至少有一個完整 course 才進入該檢驗；no-op 或缺失 cells 保留在 ex-

clusion ledger。完整 courses 先在歌內平均，因此兩個統計量的推論單位都是歌曲，而非譜或 course。

具範圍的 controls 測試各宣告 family 內的不變性。identity 重算對每個保留測量皆須精確相同；音符、authored grid 與 duration 共同平移 +1 秒，對 timing、density、grammar、structure 不變；Don-Ka 顏色雙射只作為 timing 與 density 的 sham，不假定它對 grammar 或 form 中立；60 ms 的 C2 平移則是 chart-only density、grammar、structure 的 sham。必要 control 失敗使受影響檢驗為 inconclusive，不會被平均掉；各 metric 的等價容差與 timestamp 捨入規則固定在釋出契約中。chart-only 的間隔運算使用整數微秒時鐘，比最小報告容差細三個數量級，使 interval token 與半開密度視窗在時間原點平移下保持不變。

點估計為 song-level 值的平均。我們用 seed 20260712 做 10,000 次 song-cluster bootstrap，報 nominal 95% percentile intervals；十個主要檢驗的 confirmation gate 使用 Bonferroni-adjusted 99.5% intervals。一個檢驗只有在至少 72/80 首歌可評、controls 通過、且兩個統計量的調整上界都低於零時才為 SURVIVES。相同 gates 通過後，任一統計量的調整下界大於等於零則為 REFUTED；其餘為 INCONCLUSIVE。C5 的凍結組合規則要求兩個 co-primary 檢驗都存活；§4.2 顯示它們測的是同一個有效軸。provenance、panel 或 hash 失敗則為 INVALID。

確認只在完整協定——資料集版本、損壞與劑量、主要測量、controls、閾值、校準與原始碼——以雜湊 manifest 凍結後才開啟；任何不符都會在產生 verdict 前中止執行。C5 LM 固定為完整 stored-order train split、trigram order 3、 $\text{add-}\alpha = 0.05$ 。

3.6 受評系統

我們評估五個公開生成器，跨三種音符格式：兩個太鼓系統——Mapperatorinator v32 [17]（社群開發、MIT 授權的多模式 osu! beatmap 生成框架，此處以 taiko 模式評估）與 FDG 發表的 TaikoNation [2]（自作者公開研究 repo 重現¹）——再加上僅施用時值與音樂呼應測量的三個系統：Dance Dance Convolution 的 onset 管線 (ddconset) [1]、GenéLive! 的公開 timing-only 配置 [3]、以及 osu! 難度目標生成器 AutoOsu [18]。三種格式為太鼓音符類型、timing-only onset 流、osu! 位置型物件。全部系統在其公開推論配置下，從音訊為同一批 40 首 development 歌曲製譜；本研究未在此語料上訓練或微調這些系統，但這些商業歌曲與各系統自身訓練資料的重疊無法排除 (§5)。course 對映在釋出配置中明確：Mapperatorinator 使用對應的太鼓 course；GenéLive! 的 Beginner、Easy、Medium、Hard、Challenge 設定對映到 Easy、Normal、Hard、Oni、Ura，歌曲無 Ura 譜時 Challenge 以 Oni 為參照 course；單一設定系統使用宣告的 Oni 參照。格式轉換到評估事件流在同一音符格式內共用 (§4.7)。同批歌的人類譜提供參照列。難度條件式系統對每個可得 course 各產一譜（170 或 200 張）；其餘每歌一譜（40 張）。這些 profiles 是描述性的 development analyses，不屬於凍結的 confirmation gate。

¹TaikoNation repo 未聲明軟體授權。released artifact 含 provenance 與衍生指標紀錄，不含 TaikoNation 程式碼、checkpoint、輸入素材或生成譜資料。




圖 2: 為何時值需要整譜估計。左: 最近格點配對可能把被平移的音符配到不同細分點、報出很小的局部誤差。右: 我們測試候選的整譜偏移, 選擇格線一致性最強者。格線如圖 1。

受控損壞 (強度)	改變什麼	凍結的主要反應
C1 時值抖動 ($\pm 10/20/30$ ms)	音符時值	timing.clean_rate $\downarrow$
C1s 稀疏時值錯誤 (名目 0.5/1/2%, ± 60 ms)	少數音符時間	timing.absolute_error_p99_ms $\uparrow$
C2 整體平移 (+15/30/60 ms)	譜-音訊對齊	timing.grid_phase_offset_abs_ms $\uparrow$
C3 音符類型置換 ($p=0.2/0.4/0.8$)	局部轉移	transition_validity_score $\downarrow$
C4 循環崩解 ($p=0.3/0.6/1$)	重複與形式	repetition_adequacy_score $\downarrow$
C5 常見模式改寫 ($p=0.3/0.6/1$)	pattern 多樣性	repetition_adequacy_score $\downarrow$
		surface_variety_adequacy_score $\downarrow$
C6 音符率縮放 ($\times 0.5/1.5/2$)	難度適配	density_adequacy_score $\downarrow$
C7 爆發插入 (2/4/8 叢)	局部過載	density_spike_score $\downarrow$
C8 小節順序洗牌 ($p=0.3/0.6/1$)	全局形式	repetition_adequacy_score $\downarrow$

表 2: 凍結的損壞與十個主要損壞-測量檢驗。170-chart development matrix 對每個非零 cell 使用一個 realization, 共產生含原譜 4,760 張變體; confirmation 使用五個 seeded replicates。C3–C5 保留音符時間, C4 與 C6 保存或控制密度。C1s 把譜中 n 個音符的 $\max(1, \text{round}(np))$ 個移動 ± 60 ms。C5 的 pattern-IC 與 raw pattern NLL 是沒有方向性 gate 的 secondary analyses。

4 結果

4.1 宣告測量會對目標缺陷作出反應

十個宣告檢驗全數通過兩項確認門檻, 32 項指定控制全數通過, 而且每項分析都保留 80 個歌曲群組 (表 3)。由於兩個 C5 檢驗代數等價 (§4.2), 八項具名輸出上的十個檢驗, 收斂為橫跨七個有效輸出軸的九個非冗餘損壞-測量檢驗。

正式執行從 333 張譜產生 50,283 筆紀錄。C1s 保留 332 個完整 course, C8 保留 330 個, 其餘各檢驗皆保留 333 個。32 項控制全數通過, 觀察到的最大絕對差異為零; 19 筆確定性 no-op 保留在釋出的 exclusion ledger 中。

4.2 C5 依賴關係只留下單一有效軸

正式的 C5 all-pairs 規則在機械上成立, 因為兩項具名測量都在常見模式改寫下惡化; 但兩者不能解讀為相互佐證的測量。repeated 4-gram rate 正好等於一減 unique 4-gram rate, 鏡像的 symmetric-band 分數除浮點誤差外完全相同。因此, C5 只確立一個有效 4-gram 重複 / 唯一性檢驗的敏感度。

pattern-IC 範圍分數維持為不設方向的次要分析: 其最大劑量變化為 $+0.021$, nominal 95% 區間為 $[-0.034, 0.077]$; 劑量統計量同樣跨過零 (-0.106 ,

$[-0.225, 0.016]$)。raw pattern NLL 從 2.087 降至 1.715 (最大劑量變化 -0.373 , 95% CI $[-0.399, -0.346]$)。LM 因而賦予改寫譜更高似然, 卻未建立 pattern 改善。可支持的跨軸結果更窄: 有效的 4-gram 檢驗抓到 pattern-IC 與 LM likelihood 未標為損壞的改寫。若要檢驗獨立互補性, 必須事前指定真正不等價的結構測量。

4.3 本文所提元件的行為

表 1 中僅有發展證據的元件, 是以候選測量的身分評估, 不提出保留資料信賴度主張。把原譜與三個劑量合併計算的 Spearman 反應, 支持彼此不同的操作角色。交互回應在循環崩解與小節洗牌下下降 ($\rho = -.612$ 與 $-.506$), 在時值抖動與整體平移下則幾乎不變 ($-.086$ 與 $-.003$)。停滯-疏離代理量對循環崩解有強烈反應 (定向為越大越好後 $\rho = -.924$), 在時值抖動與整體平移下則實質不變 ($-.007$ 與 $+.010$)。這些結果支持發展組上的結構敏感度, 但尚未建立玩家感受到的呼應或無聊。

兩項音訊呼應測量捕捉不同時間尺度。連打首音 onset 支持度在整體平移下下降 ($\rho = -.559$); 小節層級密度-能量呼應在一致密度縮放下保持穩定 ($\rho = +.005$), 在小節洗牌下下降 ($\rho = -.386$)。它對爆發插入的反應 ($\rho = -.092$) 偏弱, 因此應具體解讀為小節尺度共變, 而非通用音訊貼分數。依難度計

Pair	凍結反應	Courses	$\bar{\rho}_{\text{dose}}$ [99.5% CI]	$\bar{\Delta}_{\text{max-sham}}$ [99.5% CI]	Verdict
C1	clean rate	333	-.744 [-.815, -.667]	-.502 [-.558, -.446]	Survives
C1s	absolute-error p99	332	-.234 [-.344, -.134]	-.306 [-.508, -.144] ms	Survives
C2	absolute grid-phase offset	333	-.916 [-.981, -.826]	-55.58 [-61.43, -49.83] ms	Survives
C3	transition familiarity	333	-.800 [-.856, -.737]	-.231 [-.262, -.199]	Survives
C4	repetition adequacy	333	-.445 [-.573, -.312]	-.165 [-.226, -.108]	Survives
C5a	repetition adequacy	333	-.358 [-.459, -.258]	-.131 [-.189, -.078]	Survives
C5b	surface-variety adequacy	333	-.358 [-.456, -.255]	-.131 [-.186, -.074]	Survives
C6	density adequacy	333	-.693 [-.784, -.579]	-.582 [-.672, -.483]	Survives
C7	density-spike limit	333	-.940 [-.950, -.930]	-.619 [-.644, -.593]	Survives
C8	repetition adequacy	330	-.589 [-.728, -.435]	-.224 [-.293, -.156]	Survives

表 3: 80 個 group_id 歌曲群組上的凍結確認。定向後數值越大越好，因此對損壞的敏感度表現為負的劑量相關，以及負的最大劑量減 sham 對比。區間為家族校正 99.5% 歌曲群組 bootstrap 區間。C5a 與 C5b 代數等價，合計只算一個有效檢驗 (§4.2)；兩列區間的微小差異來自分開的 bootstrap streams。

算的人類譜差距同樣是聯合分佈描述：它能標示不同於訓練點雲的特徵組合，卻不能判定不尋常的譜是有創意還是品質不佳。在最大強度下，其依難度計算的分數在 C3–C8 的淨方向介於 $-.32$ 與 $-.88$ 。整體平移下，每個劑量的中位變化皆為零，最大劑量淨方向為 $-.02$ 。C5 的反應只在聚合且特定劑量下成立：最大劑量時分數惡化，兩個較低劑量則沒有，各難度的方向也不一致。這些發展結果支持把元件納入釋出套件，同時保留表 1 所示的證據邊界。釋出的發展表記錄五項元件對全部九種損壞的反應。

4.4 孤立代理量可能獎勵損壞

兩個借來的指標在損壞下反號（圖 3 左）。Perplexity 獎勵常見模式：perplexity 是一張譜平均逐音符 trigram loss 的指數。發展組人類譜平均為 9.44；向 LM 最常見模式改寫，使 perplexity 下降 37% ($9.44 \rightarrow 5.98$)。Dance Dance Convolution 把 perplexity 作為保留人類譜上的模型適配度 [1]；若移植到生成結果作為無參照品質讀數，通常的「越低越好」解讀便會偏好受損譜。這是似然 / 品質背離 [19] 的譜面層級實例。一個 LM 產生改寫、另一個 LM 評分時，反轉仍然存在 ($9.44 \rightarrow 6.04$, -36%)。pattern-IC 範圍分數移向其人類範圍，且隨三個劑量上升。因此，校準無法單獨修復 C5：這一軸量的是典型性，而改寫後的譜可以在失去多樣性時變得更典型。有效的 4-gram 軸 (§4.2) 在發展組上從 0.99 降至 0.87。結構度獎勵崩解：以譜面自身最主要的 4-gram 循環取代原譜，使自相似結構度 [9] 上升 62% ($0.0848 \rightarrow 0.1370$)、集合層級 Self-BLEU [6] 從 0.845 上升至 0.898——copy-paste 輸出依構造會更加自相似——而 4-gram 重複 / 唯一性分數則從 0.99 降至 0.83。

另外兩項觀察結果補足論證。方向不穩定：對 §4.7 兩個公開可得、輸出位於人類語料高 entropy 側的太鼓生成器，perplexity 以預期方向區分人類與生成譜 (AUC 0.80)；但 C5 證明相同讀法在低 entropy 側會反轉。若帶號品質指標的符號取決於系統位在人類分佈的哪一側，它便不能用來排名；同難度範圍分數把兩側一致解讀為偏離典型性。C5 顯示該分數為何必須與 4-gram 重複 / 唯一性軸合併閱讀。譜長混淆：在相同系統池上，type-token ratio 與音符數的相關為 $|\rho| = 0.85$ ，distinct-2 為 0.56，範圍分數則至多為 0.28。

4.5 外部時間揭露整體錯位

地板在此失守：一張譜的密度、pattern 與音符類型——主要只讀譜面讀數——可以看似合理，同時相對音樂偏晚。C2 把每個音符平移相同的 15、30 或 60 ms。在發展組上，沒有任何主要只讀譜面輸出，變化超過 0.03 個人類標準差。這符合預期：只讀取間隔與音符類型的測量，在所有時間平移同量時不會改變。

最近格點配對也錯過平移，因為密格線把每個音符配到另一個鄰近點。格線相位偏移搜尋則從兩種參照來源都回收精確中位數 15.00、30.00 與 60.00 ms。每個來源、每個平移量下，至少 169/170 張譜落在注入值的 3 ms 內。連打首音 onset 支持度測量也在音符 onset 處偵測到平移（各強度淨方向 -0.74 至 -0.88 ），並在音符時間保留時保持不變。在密集時值抖動 (C1) 下，每張譜在每個強度的 6 ms 內音符比例都下降； ± 10 ms 時，測得容差外比例的中位數為 0.40，符合 $P(|U(-10, 10)| > 6) = 0.4$ 。

4.6 不同測量抓到不同缺陷

三種損壞顯示結果為何必須維持分開（圖 3、圖 4）：

- C2 整體平移對每個主要只讀譜面測量與最近格點配對都不可見；格線相位偏移搜尋與連打首音 onset 支持度能偵測它。
- C1s 稀疏時值錯誤多數被最近格點重新配對，因此平均時值誤差的跨譜中位數維持為零。音符序列 LM 反應強烈，因為移動一個音符會改變兩個相鄰間隔；密度實質不變，形式只有微弱反應。
- C5 常見模式改寫在發展組降低 perplexity、提高 pattern-IC 範圍適配；確認性 pattern-IC 區間跨過零，raw NLL 仍下降。有效的 4-gram 重複 / 唯一性檢驗惡化，提供跨軸涵蓋。

每一組都漏掉另一組能偵測的缺陷。若將它們平均，便需要目前證據無法提供的權衡權重。

4.7 系統 profiles

發展組的系統 profiles 中，兩個問題彼此分離。圖 5–7 展示單一數字掩蓋重要差異的兩種方式。

相似的時值比例可能源自不同問題。在圖 5 中，近乎為一的人類列是以其作者編定小節 metadata 作為參照的一致性檢查，不是模型結果。兩個太鼓系統落在 6 ms 內的音符中位比例幾乎相同 (0.59 與 0.58)，其餘




圖 3: 一個測量漏掉缺陷、另一個測量加以偵測的兩個案例。長條顯示相對原譜上升的譜比例減下降比例；由淺至深標示發展組上的三個損壞強度（描述性結果，非獨立譜信賴敘述）。左：常見模式改寫使 LM loss 下降、pattern-IC 範圍分數上升，4-gram 重複 / 唯一性軸則往反方向移動（其兩個代數等價的凍結名稱只畫一次）。右：稀疏的 ± 60 ms 時值錯誤使平均時值誤差接近零、且多被最近格點重新配對，音符序列 LM 則對改變的間隔作出反應。




圖 4: 14 個非冗餘 calibrated chart-only scores 對各損壞在發展組最大強度下的反應，涵蓋 band-typicality scores 與單側 checks。紅色表示分數下降、藍色表示上升；數值以人類參照譜的標準差為單位，截斷於 ± 4 。黑框標示先在發展組選定、再凍結供確認的目標列，並非統計顯著性。C1s 使用名目 0.5–2% 劑量，所以格子偏淡；圖 3 的原始音符序列測量仍能偵測。完整的釋出矩陣隨指標紀錄提供。

時值行為卻不同：Mapperatorinator 有 10% 的相鄰間隔超出相對容差，TaikoNation 則為 41%。格線相位偏移搜尋得到 26 與 55 ms 的中位偏移；最近格點配對對兩者卻都報告不到 1 ms 的 6 ms deadzone 外平均誤差。TaikoNation 的譜面活動與音訊能量也幾乎無關（相關 -0.003 ），音符落在平均能量的 frame 上。DDC onset 系統在相同音訊上得到 2.5 ms 偏移，可作為共享解碼偏移的控制。與 Mapperatorinator 共用 osu! 轉換路徑的 AutoOsu 讀出 19 ms 中位偏移；不同的數值排除了共同轉換常數作為唯一解釋 (§3.6)。

指定 **course** 會改變讀數。Mapperatorinator 的生成 / 人類音符率比，從 Easy、Normal 的 2.15–2.35 降至 Oni 的 1.31 與 Ura 的 1.07（圖 6）。其音符率、短間隔

與局部 pattern 分數在 Easy 至 Hard 低於 0.5，在 Oni 與 Ura 則接近 1。時值沒有相同趨勢：落在 6 ms 內的中位比例依序為 0.56、0.60、0.59、0.57 與 0.62。因此，可支持的主張是難度不匹配，而非高難度下的全面改善。TaikoNation 只有單一設定；在該設定下，音符率與短間隔負荷落在人類範圍，卻有 55% 的 trigrams 未見於依難度訓練的 LM，重複 4-gram rate 為 0.004。這些是不同弱點，不能作為單一總排名的基礎。

5 討論

ChartGenEval 的貢獻位於指標套件層級：每項輸出都有宣告的構念、解讀角色與證據層級；各維度保持分




圖 5: 受評系統在 40 首發展歌曲上的時值，使用作者編定格線。每條顯示落在 6 ms 內、6–12、12–18、18 ms 以上或未配對的平均音符比例； n 為譜數。右側顯示 6 ms 內比例的第 10 百分位、中位數、第 90 百分位與最差譜面。




圖 6: Mapperatorinator 在配對發展譜上的探索性難度 profile。Easy 至 Oni 各含 40 個歌曲–course 配對；Ura 含 10 個。(a) 與 (c) 的點為中位數，豎線跨第 10 至 90 百分位。(a) 生成 / 人類音符率比；1 表示密度相等。(b) 依宣告角色分列的 calibrated score 中位數：四欄 band-typicality，1 表示位於範圍內，另一欄單側轉移熟悉度、越大越好。(c) 音符落在作者編定格線 6 ms 內的比列。

開，因為時值偏移、不熟悉的轉移、密度不匹配與結構停滯，描述的是不同問題。凍結確認承載保留資料證據 (§4.1)；其餘本文提出的元件維持僅有發展證據的狀態。

非典型是警示，不是品質判決。地板是必要條件而非充分條件：在地板之上，品質容許多種答案。受控損壞顯示，已知損壞傾向把分數推出人類範圍，卻不

能證明所有不尋常的譜都不好。若一張譜仍可玩、貼合音樂且保留可學習的 pattern，不尋常數值可能反映創意選擇；若其他檢查也失敗，相同數值才更支持失效解讀。兩者仍需人類判斷加以區分。距離尺度可協助理解大幅偏離：發展組人類譜在序列軸上的最大值為 4.8 個半範圍寬，Mapperatorinator 與 TaikoNation 的

	timing within 6 ms	note rate	short intervals	familiar trans.	local patterns	4-gram repetition/uniqueness	overload	playable	slope
human reference	1.00	1.00	1.00	0.75	1.00	1.00	✓	✓	✓
Mapperatorinator	0.59	0.23	0.36	0.23	0.19	1.00	✓	✗	✓
TaikoNation	0.58	1.00	1.00	0.00	0.01	0.08	✓	✓	✓

圖 7: 人類參照與兩個使用太鼓音符類型的生成器，在發展組上的分開結果。第一欄是音符落在格線 6 ms 內的中位比例；其餘格為 $[0, 1]$ 的 calibrated scores。音符率、短間隔、局部 pattern、4-gram 重複 / 唯一性各欄的 1 表示中位數落在人類範圍；轉移熟悉度是單側分數（越大越好），連人類參照也只有 0.75，因為 LM 仍會遇到未見的 trigrams。右側符號以中位閾值 0.5 分開顯示過載、尖峰與可玩性檢查。其他音符格式只出現在時值比較（圖 5）。

中位數則分別為 2.1 與 12。本文只有 §4.7 的 course 不匹配，完整示範了如何合併解讀這些訊號。

超越單一遊戲。時值與音樂呼應測量只讀音符時間，因此可原樣施用於三種音符格式。序列、形式與距離測量還需要目標遊戲的 tokenizer，以及供校準的人類譜；lane、位置或方向 token 都可取代太鼓音符類型。受控損壞作用於一般的定時、定型事件，因此相同設計可以測試哪些宣告反應能轉移到另一款遊戲。位置型遊戲仍需移動成本、手部分配與旋轉等額外檢查；目前測量不涵蓋這些要求。

效度範圍。受控損壞只確立對注入缺陷的敏感度，並未建立以玩家或專家評分為效標的效度。九種損壞不窮盡譜面品質：配錯歌曲、刪除音樂上重要的音符、刻意把音符放在格點之間等情況仍未測試。所報方向是群體結果，個別譜面在損壞後仍可能移向人類範圍。五項本文提出且僅有發展證據的元件，在提出更強品質主張前，仍需未接觸資料確認或玩家研究。凍結 C5 契約也曾把重複與表面多樣性當成兩個共同主要測量；其代數等價性只留下單一有效檢驗，未來確認應改用不等價的結構測量。

外部效度。人類範圍由單一遊戲、曲風廣度未明的語料定義。其他音符格式的系統只受評時值與音樂呼應，而且每個系統都只以其公開設定的一個 seed 執行。發展歌曲與系統訓練語料可能重疊，本研究未加以控制。各格式轉換偏移雖受 §4.7 的共用路徑比較約束，仍無法完全排除。因此，系統 profiles 是比較性描述，不是排行榜。

測量與推論。時值與序列反應會重疊，因為序列 token 包含音符間隔（圖 4）。時值 clean rate 會懲罰新增的離格音符，卻沒有參照 recall 項，因此刪除可能提高分數；沒有外部格線時，這項測量也無法計算。正式確認使用作者編定格線，音訊估計格線只有發展證據。course 先在歌曲內平均，因此歌曲是推論單位；同一作者跨歌曲可能造成的依賴尚未建模。確定性的五 seed replicates 先在譜內平均，從未當成額外樣本。

6 結論

我們提出 ChartGenEval，一套以地板優先觀點建立的節奏遊戲譜面六維度指標套件。時值是音樂貼合度的

地板，套件只以官方譜面的作者編定時值圖測量它，從不使用其音符位置。在地板之上，本文提出的元件刻畫音樂呼應、長程結構與距人類譜的距離；既有譜面統計量的難度條件化版本，則補足序列、重複、密度與限制讀數。原始描述、雙側典型性與單側檢查保留各自角色，不合成整體分數。

受控損壞支持九個非冗餘保留資料檢驗；其餘本文提出的元件目前只有發展證據。相同實驗也解釋套件為何必須維持分開：perplexity 可能獎勵常見模式改寫，自相似度可能獎勵循環崩解，主要只讀譜面輸出則無法偵測相對音樂的整體平移。整譜格線相位偏移補上最後這個盲點，又不把單一參照音符序列視為答案。這些發現確立目前語料與設計範圍內的損壞敏感度。

施用於公開生成器後，分開輸出揭露單一排名會掩蓋的時值、序列、密度與 course 特定弱點。我們於 <https://github.com/JacobLinCool/ChartGenEval> 釋出實作與證據。未來的譜面指標可以先宣告所服務的構念與角色，再證明它會對目標缺陷作出相應反應，並在指定不變性控制下保持穩定，據此納入套件。

倫理聲明

本研究使用 §3.2 所述、自網路來源蒐集的社群轉錄譜面與對應音訊；這些潛在受版權保護的譜面與音訊不隨本文再散布。本研究不涉及個人資料。更好的自動評估主要惠及玩家與小型開發者。自動化內容農場仍是可能的濫用途徑，應由平台政策與審核機制處理。

AI 使用聲明

AI 助理在作者指導下用於實驗編排、起草與編輯；所有數字皆由釋出程式碼產生、獨立重算並由作者查核。

參考文獻

- [1] C. Donahue, Z. C. Lipton, and J. McAuley, “Dance dance convolution,” in *Proceedings of the 34th International Conference on Machine Learning*,

- ser. *Proceedings of Machine Learning Research*, D. Precup and Y. W. Teh, Eds., vol. 70. Sydney, Australia: PMLR, Aug. 2017, pp. 1039–1048. [Online]. Available: <https://proceedings.mlr.press/v70/donahue17a.html>
- [2] E. Halina and M. Guzdial, “TaikoNation: Patterning-focused chart generation for rhythm action games,” in *The 16th International Conference on the Foundations of Digital Games (FDG) 2021*, ser. FDG ’21. New York, NY, USA: Association for Computing Machinery, Aug. 2021, pp. 1–10. [Online]. Available: <https://doi.org/10.1145/3472538.3472589>
- [3] A. Takada, D. Yamazaki, Y. Yoshida, N. Ganbat, T. Shimotomai, N. Hamada, L. Liu, T. Yamamoto, and D. Sakurai, “Genélive! generating rhythm actions in Love Live!” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 4, pp. 5266–5275, Jun. 2023. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/25657>
- [4] J. Hanzen, E. Halina, and M. Guzdial, “Time-based chart partitioning: Improving local coherency in rhythm game chart generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 21, no. 1, pp. 43–51, Nov. 2025. [Online]. Available: <https://ojs.aaai.org/index.php/AIIDE/article/view/36808>
- [5] J. Li, M. Galley, C. Brockett, J. Gao, and B. Dolan, “A diversity-promoting objective function for neural conversation models,” in *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, K. Knight, A. Nenkova, and O. Rambow, Eds. San Diego, California: Association for Computational Linguistics, Jun. 2016, pp. 110–119. [Online]. Available: <https://aclanthology.org/N16-1014/>
- [6] Y. Zhu, S. Lu, L. Zheng, J. Guo, W. Zhang, J. Wang, and Y. Yu, “Texygen: A benchmarking platform for text generation models,” in *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, ser. SIGIR ’18. New York, NY, USA: Association for Computing Machinery, Jun. 2018, pp. 1097–1100. [Online]. Available: <https://doi.org/10.1145/3209978.3210080>
- [7] L.-C. Yang and A. Lerch, “On the evaluation of generative models in music,” *Neural Computing and Applications*, vol. 32, no. 9, pp. 4773–4784, 2020. [Online]. Available: <https://doi.org/10.1007/s00521-018-3849-7>
- [8] H.-W. Dong, K. Chen, J. McAuley, and T. Berg-Kirkpatrick, “MusPy: A toolkit for symbolic music generation,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 101–108. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000187.pdf>
- [9] S.-L. Wu and Y.-H. Yang, “The jazz transformer on the front line: Exploring the shortcomings of AI-composed music through quantitative measures,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 142–149. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000339.pdf>
- [10] M. Gover and O. Zewi, “Music translation: Generating piano arrangements in different playing levels,” in *Proceedings of the 23rd International Society for Music Information Retrieval Conference (ISMIR 2022)*, Bengaluru, India, Dec. 2022, pp. 36–43. [Online]. Available: <https://archives.ismir.net/ismir2022/paper/000003.pdf>
- [11] J. Wang, W. Huang, and X. Li, “Mania archetype: Chart generation for rhythm action games with human factors,” in *Human Factors in Virtual Environments and Game Design*, vol. 137. AHFE Open Access, 2024, pp. 175–185. [Online]. Available: <https://doi.org/10.54941/ahfe1005000>
- [12] M. Plasser, S. Peter, and G. Widmer, “Discrete diffusion probabilistic models for symbolic music generation,” in *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*. International Joint Conferences on Artificial Intelligence Organization, Aug. 2023, pp. 5842–5850. [Online]. Available: <https://www.ijcai.org/proceedings/2023/648>
- [13] J. Retkowski, J. Stępnia, and M. Modrzejewski, “Fréchet music distance: A metric for generative symbolic music evaluation,” *arXiv preprint arXiv:2412.07948*, Jan. 2025. [Online]. Available: <https://arxiv.org/abs/2412.07948>
- [14] J. Opria, “STRUM: A spectral transcription and rhythm understanding model for end-to-end generation of playable rhythm-game charts,” *arXiv preprint arXiv:2605.12135*, May 2026. [Online]. Available: <https://arxiv.org/abs/2605.12135>
- [15] A. Friberg and J. Sundberg, “Time discrimination in a monotonic, isochronous sequence,” *The Journal of the Acoustical Society of America*, vol. 98, no. 5, pp. 2524–2531, Nov. 1995. [Online]. Available: <https://doi.org/10.1121/1.413218>
- [16] J. London, *Hearing in Time: Psychological Aspects of Musical Meter*, 2nd ed. Oxford University Press, May 2012. [Online]. Available: <https://academic.oup.com/book/9899>

- [17] O. Schipper, “Mapperatorinator: An AI framework for generating and modding osu! beatmaps for all gamemodes from spectrogram inputs,” GitHub repository, May 2026, version 32.0.0; MIT-licensed software release. [Online]. Available: <https://github.com/OliBomby/Mapperatorinator/releases/tag/v32.0.0>
- [18] S. Lee and D. Jeong, “AutoOsu: Audio-aware action generation for rhythm games,” Late-Breaking Demo at ISMIR 2023, 2023, project page: <https://issyun.github.io/autoosu/>; public source repository: <https://github.com/issyun/AutoOsu>. [Online]. Available: https://ismir2023program.ismir.net/lbd_319.html
- [19] L. Theis, A. van den Oord, and M. Bethge, “A note on the evaluation of generative models,” in *4th International Conference on Learning Representations (ICLR 2016), Conference Track Proceedings*, San Juan, Puerto Rico, May 2016. [Online]. Available: <https://arxiv.org/abs/1511.01844>