

# ChartGenEval：經受控擾動測試的節奏遊戲譜面多維度回饋

Jhen-Ke Lin  
國立陽明交通大學  
jacob.cs14@nycu.edu.tw



圖 1：ChartGenEval 的六個評估維度。ChartGenEval 將譜面評估整理為六個彼此區分的问题，分屬音樂契合度與遊玩相關特性；每個維度保留各自的解讀。

## 摘要

生成的節奏遊戲譜面不必重現單一官方音符序列：同一首歌與同一難度可以有多種合理的音符選擇。因此，與官方音符的一致度主要衡量重建，而不是完整的譜面設計。我們提出 ChartGenEval：一個包含六個評估問題，並以受控擾動測試核心輸出的自動化框架。它保留音符選擇的自由，但把時值固定在歌曲上；配對的官方譜面只提供編定的時值圖，不提供目標音符。

我們不預設熟悉的統計量就能代表譜面品質，而是用可控制強度的錯誤逐一測試核心輸出。在 80 個留出歌曲群組上，七個輸出軸在九項非冗餘測試中符合預先指定的敏感度與不變性準則。40 首發展歌曲上的補充壓力測試帶來兩個結論：整譜相位估計能準確估出注入的 15、30 與 60 ms 平移，只讀譜面的輸出則幾乎不變；常見模式改寫使語言模型 perplexity 平均值下降 37%，循環崩解使自相似度平均值上升 62%。因此，ChartGenEval 分開報告各訊號，不把它們合成單一代理量或總分。這套剖面可自動比較與迭代生成器；通過特定任務的壓力測試後，部分輸出也可作為最佳化目標或限制的候選。

## 1 引言

譜面評估困難，是因為譜面設計有多種合理答案：同一首歌與難度可以對應不同的定時、定型音符序列。自動生成已從 onset 偵測進展到條件式序列模型 [1–4]，但評估仍必須分辨合理替代方案與錯誤。

因此，與一張官方譜面的重合度有用但不完整。配置 F1 衡量的是重建：合理的替代方案會和錯誤一樣失分。其他自動代理量回答更窄的問題。語言模型 (LM) likelihood 衡量模型配適，多樣性與自相似度描述生成素材。它們都無法單獨告訴開發者是哪個譜面性質改變，也不能直接指出如何改善生成器。快速迭代需要的是彼此分開的自動回饋。

我們的關鍵觀察是：音符選擇可以自由，外部條件不能自由。譜面可以決定放什麼音符，但不能決定歌

曲的音樂時間。因此，我們只使用配對官方譜面的編定小節、拍號與速度圖，不把其中的音符位置當作目標。這個拆分保留不同設計，同時能揭露只看間隔與類型的統計量看不到的整譜平移。

ChartGenEval 把評估整理成圖 1 中的六個問題。通過受控擾動測試的核心輸出涵蓋時值、局部音符序列、局部重複，以及難度或可玩性限制。每個輸出保留自己的角色：方向明確的訊號可引導最佳化，可行性檢查可作為限制，描述值則可監測模型行為。這些角色不會被合成一個總分。

我們以逐步加強的已知錯誤測試核心輸出。有用的輸出應回應目標錯誤，並在預先指定的不變性控制條件下維持不變。七個輸出軸在 80 個留出歌曲群組的九項非冗餘測試中通過準則。發展組的補充壓力測試帶來兩個可直接使用的結論。第一，時值必須固定在歌曲上：相位估計能準確估出只讀譜面統計量漏掉的 15–60 ms 整譜平移。第二，看似合理的代理量可能獎勵錯誤行為：常見模式改寫改善 perplexity，循環崩解則提高自相似度。

我們的貢獻如下：

1. 自動化的分維度回饋。ChartGenEval 分開評估問題與輸出角色，讓開發者不必把單一參照音符序列當作唯一答案，也能比較與修改生成器。
2. 通過擾動測試的訊號與可重用的診斷結論。九項非冗餘留出測試支持七個核心輸出軸；發展組補充測試則找出只讀譜面時值統計的平移盲點，以及 perplexity 與自相似度的反向誘因。

## 2 相關研究

參照譜一致度衡量的是對單一編定序列的重建。DDC 與 GenéLive! 對預測位置報告 F-score，TCP 再加入 onset-plus-type F1 與局部 pattern recall [1, 3, 4]。TaikoNation 比較二元時值 frame 與 pattern space [2]。這些測量適合評估重建，但仍把一張編定序列視為答案。

無配對統計與人類研究回答互補的問題。DDC 以 LM perplexity 與 token accuracy 衡量留出模型配適 [1]。符號音樂與文字生成研究另提供多樣性、分布、自相似度與重複統計 [5–9]。人類與專家研究則評估整體系統經驗 [3, 10, 11]。ChartGenEval 補上另一個問題：自動輸出是否會對指定的譜面錯誤作出正確反應。

指標壓力測試顯示，看似合理的統計量仍可能漏掉音樂問題。SCHmUBERT 建構非音樂性的 piano roll，卻能匹配逐 frame 自相似統計 [12]。Fréchet Music Distance 以音高與力度擾動測試，但仍是集合層級的 embedding 距離 [13]。STRUM 在逐歌搜尋整體偏移後報告參照 onset F1 [14]；ChartGenEval 則直接報告偏移本身，不使用參照音符作為目標。受控擾動同時測試目標回應與不變性，讓 metric 的選擇成為可以驗證的問題。

### 3 方法

#### 3.1 評估問題與核心輸出

ChartGenEval 把圖 1 的六個維度視為六個不同問題。主文聚焦七個已通過留出受控擾動檢驗的輸出（表 1）。時值使用三個讀數，因為密集誤差、少數極端誤差與整譜偏移是不同問題。其餘輸出分別檢查局部轉移、局部重複、指定難度的音符率，以及密度尖峰。

所有輸出都能自動計算，但用途不同。格線相位誤差與時值尾部有明確方向；密度尖峰提供同難度的密度限制；轉移熟悉度與典型性較適合作為軟性目標或監測訊號。原始 LM loss 只用來描述模型配適與作為壓力測試基準。尤其，訓練語料未見的轉移只代表它對該語料不熟悉，不代表它一定無效。

#### 3.2 同難度校準

有些譜面特性沒有「越多越好」的通則。譜面可能太疏或太密，重複太少或太多也都可能有問題。因此，我們測量特徵偏離同難度人類譜中間 80% 範圍的程度。對特徵值  $x$ ，令  $l$  與  $u$  為訓練集第 10 與第 90 百分位，並令  $h = \max((u - l)/2, 10^{-9})$ 。範圍分數為

$$d(x) = \begin{cases} (l - x)/h, & x < l, \\ 0, & l \leq x \leq u, \\ (x - u)/h, & x > u, \end{cases} \quad (1)$$

$$s(x) = \frac{1}{1 + d(x)^2}.$$

範圍內的  $s(x) = 1$ ，超出範圍後則對稱下降。這是依難度條件化的典型性讀數，不是對創意或整體品質的判決。密度尖峰等單側限制仍分開計算，因為嚴重的局部過載不應被另一個高分抵消。

三個較不熟悉的輸出使用簡單轉換。若  $r$  是同難度訓練譜未見的間隔-類型 trigram 比例，轉移熟悉度為  $\exp(-r/0.08)$ 。若  $M$  個 4-gram 視窗中有  $U$  個不重複視窗，校準前的重複率為  $(M - U)/M$ 。密度尖峰分數為  $\exp(-e/1.5)$ ，其中  $e$  是譜面第 95 百分位局部密度跳升超過同難度限制的幅度。

#### 3.3 資料與時值錨點

我們把設計與確認分開：先在 40 個發展歌曲群組的 170 張譜上設計七個核心輸出及其擾動，再於 80 個留

出群組的 333 張譜上檢驗。校準集另包含 813 個歌曲群組、共 3,880 張各難度譜面。推論單位是歌曲，不是難度譜面或擾動複本。附錄 A 說明語料建構、完整性規則與完整分析協定。

時值需要生成事件序列以外的參照。格線取自配對官方檔案中由作者編定的逐小節時間戳、拍號與速度。我們從不把官方譜面的音符時間或類型當成目標，也不接受生成譜自行宣告的格線。前者保留音符設計的自由，後者避免生成器重新定義評估它的時鐘。

#### 3.4 對歌曲測量時值

共同平移  $\delta$  不會改變任何相鄰音符間隔：

$$(t_{i+1} + \delta) - (t_i + \delta) = t_{i+1} - t_i. \quad (2)$$

音符類型也不變。因此，只依這些間隔與類型計算的譜面內部測量無法辨識這個平移。這個平移對稱性在實驗之前就指出了盲點。

局部時值需要同時摘要常見誤差與少數大誤差。我們把距作者編定格線 6 ms 內的音符視為局部對齊；這個尺度接近已發表的短間隔時間辨別門檻 [15]。時值容差內比例摘要常見誤差，絕對誤差第 99 百分位則揭露平均值容易遮住的少數大誤差。未配對的生成音符仍在分母內，因此時值容差內比例必須與音符率一起解讀。完整配對規則與 6/12/18 ms 診斷範圍見附錄 A。

最近格點配對可能錯過恆定平移（圖 2）。在密格線上，每個被平移的音符可能只是與另一個鄰近格點配對，因此我們改對整張譜估計單一偏移。令  $G_k$  表示固定的小節、拍與八分音符格線，並定義  $d(x, G_k) = \min_{g \in G_k} |x - g|$ 。對音符時間  $t_i$ ，候選平移的分數為

$$S(\delta) = \sum_k w_k \frac{1}{n} \sum_i \left[ 1 - \frac{d(t_i - \delta, G_k)}{\tau} \right]_+, \quad (3)$$

$$\hat{\delta} = \arg \max_{\delta \in [-250, 250] \text{ ms}} S(\delta),$$

其中  $[z]_+ = \max(z, 0)$ 、 $\tau = 12 \text{ ms}$ ，小節、拍與八分音符格線的權重依序為 0.2、0.3 與 0.5，搜尋間隔為 0.5 ms。合併三層格線可減少週期性平手。所得  $\hat{\delta}$  是整譜診斷量，其幅度表示譜面要移動多少才最符合固定的音樂時間框架。BPM 只有週期、沒有相位，因此不能取代這個錨點。

#### 3.5 受控擾動與判定準則

每種擾動從人類譜出發，逐步加強一項操作性錯誤。其他輸出也可能同時改變，因此測試確認的是目標敏感度，不是排他的專一性。目標輸出與預期方向都在留出檢驗前固定；完整轉換見附錄 B。

把輸出方向統一為越大越好後，獲得支持需要三個條件：劑量等級關聯為負、最大強度相對配對控制的變化為負，而且所有相關不變性檢查都通過。我們使用以歌曲為群集的 bootstrap 區間，並校正十個預先指定的檢驗。完整判定規則與樣本數見附錄 A。

| 評估問題   | 自動讀數                          | 目前證據                        |
|--------|-------------------------------|-----------------------------|
| 時值     | 時值容差內比例、時值誤差 p99、整譜格線相位偏移     | C1、C1s、C2 留出檢驗              |
| 音符序列   | 由未見間隔-類型 trigram 比例轉換的單側熟悉度分數 | C3 留出檢驗                     |
| 重複與曲式  | 重複與獨特 4-gram 相對同難度人類譜的典型性     | C4、C5、C8 檢驗局部重複；長程曲式讀數仍屬探索性 |
| 音樂呼應   | 小節層級的能量呼應與 onset 支持           | 發展組探索性分析；附錄 C               |
| 人類譜面距離 | 與同難度訓練分布的距離                   | 發展組探索性分析；附錄 C               |
| 難度與限制  | 同難度音符率典型性與局部密度尖峰限制            | C6、C7 留出檢驗                  |

表 1: 六個問題的證據強度不同：七個核心輸出具有留出檢驗；音樂呼應、人類譜面距離與長程曲式讀數仍屬探索性。




圖 2: 為何時值需要整譜估計。左：最近格點配對可能把平移後的音符配到不同細分點，因此仍報出很小的局部誤差。右：整譜候選偏移的一致性曲線在注入的 +60 ms 平移處達到最高。局部看似合理，不代表譜面相對歌曲的時間正確。

## 4 結果

### 4.1 核心輸出會回應目標錯誤

每個核心輸出在目標錯誤下都有預期的負向劑量等級關聯（表 2）。九組非冗餘的擾動-測量配對涵蓋七個輸出軸，因為同一個 4-gram 軸可偵測三種不同改動。所有適用的不變性控制都通過。重點不是每種錯誤都需要新指標，而是少量可解讀的輸出，只要各自通過具體的失敗測試，就能涵蓋不同問題。

稀疏誤差說明了為何大多數音符仍正確時，必須用尾部統計量才能看見問題。完整樣本數與排除規則見附錄 A。

### 4.2 外部時間能偵測譜面-歌曲偏移

平移對稱性預測：譜面內部可以看似合理，卻整體晚於歌曲。40 首發展歌曲的實驗確認了這個機制。把所有音符平移 15、30 或 60 ms 後，沒有任何主要譜面內部輸出的變化超過人類標準差的 0.03 倍。相位估計的中位數符合每個注入平移；使用作者編定格線時，169/170 張譜的相位估計變動量與注入平移相差在 3 ms 內。

局部配對與整譜相位回答的是不同問題。密格線可把平移後的音符配到另一個細分點，仍得到很小的局部誤差；整譜估計則保留所有音符共有的偏移。相同原理也適用於稀疏錯誤：平均值由大量正確音符主導，時值誤差 p99 才能看見尾部。因此，時值評估同時需要歌曲端錨點與不同尺度的摘要。

### 4.3 常用代理量可能偏好錯誤行為

兩個常用代理量在目標錯誤下朝錯誤方向移動（圖 3）。LM perplexity 會獎勵常見模式改寫：在發展組上，平均 perplexity 下降 37%，從 9.44 降到 5.98。若採「越低越好」的解讀，便會偏好擾動後的譜面，方向與目標特性相反 [16]。使用另一個分開擬合的 LM 評分後，反轉仍存在；4-gram 典型性則往人類範圍外移。次要檢查見附錄 C。

若把自相似度當作品質目標並加以提高，它會獎勵循環崩解。反覆使用最常見的 4-gram，會讓平均自相似度上升 62%，即使音符類型序列已縮成反覆出現的四事件循環 [9]。4-gram 典型性則往相反方向移動。實用原則是：把指標當成獎勵前，先用它原本想避免的錯誤進行壓力測試。

分維度的自動回饋能指出模型版本改變了哪一種失敗機制，因而縮短模型開發的回饋時間。相位誤差與時值尾部可作為降低的候選訊號；密度尖峰提供同難度的限制；熟悉度與典型性適合作為軟性目標或監測訊號。最佳化方法可在特定任務的壓力測試後選用部分訊號，但不應把單一數字當成獎勵。

| 目標錯誤          | 核心輸出       | 劑量趨勢 [99.5% CI]      | 最大強度變化 [99.5% CI]          |
|---------------|------------|----------------------|----------------------------|
| 密集時值抖動        | 時值容差內比例    | -.744 [-.815, -.667] | -.502 [-.558, -.446]       |
| 少數 60 ms 時值誤差 | 時值誤差 p99   | -.234 [-.344, -.134] | -.306 [-.508, -.144] ms    |
| 整譜平移          | 格線相位偏移     | -.916 [-.981, -.826] | -55.58 [-61.43, -49.83] ms |
| 音符類型洗牌        | 轉移熟悉度      | -.800 [-.856, -.737] | -.231 [-.262, -.199]       |
| 循環崩解          | 4-gram 典型性 | -.445 [-.573, -.312] | -.165 [-.226, -.108]       |
| 常見模式改寫        | 4-gram 典型性 | -.358 [-.459, -.258] | -.131 [-.189, -.078]       |
| 音符率縮放         | 音符率典型性     | -.693 [-.784, -.579] | -.582 [-.672, -.483]       |
| 局部爆發插入        | 密度尖峰限制     | -.940 [-.950, -.930] | -.619 [-.644, -.593]       |
| 小節順序洗牌        | 4-gram 典型性 | -.589 [-.728, -.435] | -.224 [-.293, -.156]       |

表 2: 80 個歌曲群組上的留出結果。輸出方向統一為越大越好，因此錯誤越強時，有用的反應為負。每列都符合兩項準則，所有適用控制也都通過。區間為家族校正的 99.5% 歌曲群集 bootstrap 區間。原先分開命名的 4-gram 多樣性與重複分數在代數上互為鏡像，因此只計為一個有效軸。




圖 3: 發展組上的反向誘因。常見模式改寫改善 LM loss 與其範圍分數；循環崩解提高自相似度；兩種情況的 4-gram 典型性都下降。長條表示相對原譜的淨方向，顏色越深代表擾動越強。

## 5 討論

典型性也需要脈絡。擾動常把譜面推離同難度人類範圍，但反向推論不成立：不尋常的譜面可能是有意且可玩的設計。分開的時值與可行性檢查，有助於區分創新與具體錯誤。當訊號不一致時，這個差異本身就是資訊，不必用平均值藏起來。

附錄 C.3 的公開系統剖面示範兩個可重用的閱讀方式：相近的容差內比例可能藏有不同時值尾部與整譜偏移；同一生成器也可能符合某個難度，卻在另一難度產生過多音符。這些案例不是額外的指標驗證，而是說明診斷應依失敗機制進行，而不是只看一個主分數。

## 6 限制

受控擾動只證明輸出會回應已定義的錯誤，不會產生普遍適用的譜面品質排名。目前的擾動也沒有涵蓋所有錯誤，例如配錯歌曲或刪除音樂上重要的音符。音

樂呼應、長程結構與人類譜面距離等延伸項目是在發展組上設計，仍屬探索性。

人類範圍來自單一太鼓語料。時值也需要外部格線；沒有作者編定時值圖的情形（例如改由音訊估計的格線）尚未檢驗。最後，時值容差內比例沒有參照音符的 recall，因此刪除離格音符可能提高它。這也是為何剖面必須把容差內比例與音符率一起讀，並把可行性限制分開保留。

## 7 結論

ChartGenEval 把譜面評估拆成可分開測試的自動回饋訊號。七個輸出軸通過九項留出受控擾動檢驗。發展組補充測試顯示，以歌曲為錨點的相位估計能準確估出只讀譜面統計量看不見的注入平移。這些發展組測試也顯示，likelihood 與自相似度在目標擾動下可能朝錯誤方向移動，因此都不應單獨作為品質分數。更廣泛的教訓很簡單：每個訊號都應對應具體失敗、通過目標壓力測試，並讓它在模型開發中的角色保持清楚，這時自動評估才最有用。

## 倫理聲明

本研究使用 §3.3 所述、自網路來源蒐集的社群轉錄譜面與音訊；這些可能受版權保護的材料不隨本文散布。釋出內容不包含原始譜面、音訊、個人資料或生成器。自動評估可能降低大量產製內容的成本，因此高量部署仍需遵守平台政策並保留審核機制。

## AI 使用聲明

AI 助理在作者指導下用於實驗編排、起草與編輯；所有報告數值均由作者查核。

## A 語料涵蓋與留出評估協定

### A.1 語料涵蓋範圍

校準語料依 course、星級與速度彙整。圖 4 呈現其難度與速度涵蓋。

### A.2 語料與時值細節

我們使用自網路社群資源蒐集的太鼓風格譜面與對應音訊。訓練集包含 924 筆來源紀錄，整理後形成 813 個不重複歌曲群組與 3,880 張各難度譜面。測試集包




圖 4: 定義校準範圍的人類參照語料之 course 難度與速度涵蓋。(a) 3,880 張訓練譜中, 各 course 的星級計數: 每個 course 都橫跨寬廣且逐步位移的難度範圍。(b) 速度直方圖 (中位 170 BPM, 範圍 65–376)。

含 140 筆來源紀錄, 整理後形成 120 個歌曲群組。原始譜面與音訊可能受版權保護, 因此不隨本文散布。

時值格線使用作者編定的逐小節時間戳、拍號與速度。局部時值診斷把每個生成音符分為 6 ms 內、6–12 ms、12–18 ms、18 ms 以上或未配對。相鄰間隔另使用  $\max(6 \text{ ms}, 2.5\% \times \text{IOI})$  的容差。留出絕對偏移使用作者編定格線, 因為它直接固定小節相位。

### A.3 資料組建構與完整性

來源紀錄依 group\_id 與音訊 SHA-256 正規化; 不一致的別名會在資料組索引前排除。測試集依儲存順序包含 120 個歌曲群組, 其中第 0–39 組構成發展組, 第 40–119 組構成留出組。在檢視留出結果前, 我們先固定資料集版本、擾動與劑量、目標測量、控制、閾值、校準與分析計畫。

### A.4 複本、完整性與推論單位

每個非零擾動 cell 與控制條件都使用五個固定的 base seed。複本先在每張譜、每個劑量內平均。course 只有在原譜值、所有目標劑量與複本、配對控制及必要檢查皆可時才算完整。歌曲至少有一個完整 course 才進入該檢驗; 完整 course 再於歌曲內平均。因此, 兩個反應統計量的推論單位都是歌曲, 而非譜面、course 或複本。確定性的 no-op 與缺失 cell 不進入分析。

### A.5 控制檢查與數值不變性

每項保留測量都進行 identity 重算。音符、作者編定格線與時長共同平移 +1 秒, 用於檢查對時間原點的不變性。Don-Ka 音色雙射只用於與音色無關的時值與密度測量, 不作為 grammar 或形式的控制。60 ms 的 C2 平移則是只讀譜面密度、grammar 與結構測量的配對控制。必要檢查未通過時, 對應目標反應便不能視為受到支持。每項測量均採用指定的等價容差與 timestamp 捨入規則。只讀譜面的間隔運算使用整數微秒, 比最小報告容差細三個數量級。

### A.6 區間與判定規則

把輸出定向為越大越好後, 第一個統計量是原譜加三個劑量的四種強度, 與測量之間的逐譜 Spearman 相關; 四個反應全為常數時, 敏感度定義為零。第二個統計量是定向後的最大劑量值減去指定的配對控制。點估計取歌曲層級值的平均。我們進行 10,000 次歌曲群組 bootstrap: 次要分析報告 nominal 95% 區間, 十列主要配對則使用 Bonferroni 校正的 99.5% 區間。C6 對原譜、0.5 $\times$ 、1.5 $\times$  與 2 $\times$  條件使用 [0, 0.5, 0.5, 1] 的強度, 因此等幅的偏低與偏高會並列; 並列強度使用平均等級。若至少 72/80 首歌曲可評、所有控制均通過, 且兩個調整後上界皆低於零, 該反應即獲支持。調整後下界若為非負, 則與預期反應相反; 其餘情況視為無法判定。兩列 C5 輸出必須共同符合規則, 但其代數等價性只留下單一有效軸。C5 LM 使用完整且依儲存順序排列的訓練集、trigram order 3, 以及  $\text{add-}\alpha = 0.05$ 。

### A.7 樣本數與排除

留出分析從 333 張譜產生 50,283 筆觀察紀錄。C1s 保留 332 張完整難度譜面, C8 保留 330 張, 其餘有效配對皆保留 333 張。32 項控制全數通過, 觀察到的最大絕對差異為零。另有 19 個確定性 no-op cell 遭排除。

## B 受控擾動規格

圖 5 呈現各項擾動所施加的操作性變化, 以及預先指定的目標測量。

170 張譜的發展矩陣在每個非零 cell 使用一個 realization, 連同原譜共產生 4,760 張變體。C1s 將譜面  $n$  個音符中的  $\max(1, \text{round}(np))$  個平移  $\pm 60 \text{ ms}$ 。C3–C5 保留音符時間, C4 與 C6 則保留或控制密度。原始特徵與其衍生分數都在同一批變體上計算, 等價量只計一次。C5 由一個 LM 選擇常見模式改寫, 再由另一個分開擬合的 LM 評分; perplexity 反轉仍然存在 (9.44  $\rightarrow$  6.04,  $-36\%$ )。

| 受控擾動（強度）                               | 操作性改動   | 預先指定的反應     |
|----------------------------------------|---------|-------------|
| C1 時值抖動（ $\pm 10/20/30$ ms）            | 所有音符時間  | 時值容差內比例↓    |
| C1s 稀疏時值錯誤（ $0.5/1/2\%$ ， $\pm 60$ ms） | 少數音符時間  | 時值誤差 p99↑   |
| C2 整譜平移（ $+15/30/60$ ms）               | 譜面-歌曲對齊 | 格線相位偏移↑     |
| C3 音符類型洗牌（ $p=0.2/0.4/0.8$ ）           | 局部轉移    | 轉移熟悉度↓      |
| C4 循環崩解（ $p=0.3/0.6/1$ ）               | 局部重複    | 4-gram 典型性↓ |
| C5 常見模式改寫（ $p=0.3/0.6/1$ ）             | 模式多樣性   | 4-gram 典型性↓ |
| C6 音符率縮放（ $\times 0.5/1.5/2$ ）         | 難度適配    | 音符率典型性↓     |
| C7 爆發插入（ $2/4/8$ 個叢集）                  | 局部過載    | 密度尖峰限制↓     |
| C8 小節順序洗牌（ $p=0.3/0.6/1$ ）             | 樂句順序    | 4-gram 典型性↓ |

表 3: 受控擾動、強度與目標讀數。這些編輯針對操作性錯誤，不表示已涵蓋所有譜面品質。C3–C5 保留音符時間；C4 與 C6 保留或控制密度。




圖 5: 受控擾動圖譜。藍色表示原譜，橘色表示編輯後的事件。各 panel 呈現一種擾動所針對的性質，並標示其目標測量。C1–C2 針對時值，C3 針對轉移熟悉度，C4–C5 與 C8 針對重複或形式，C6–C7 則針對難度適配與局部負荷。這些編輯不涵蓋譜面品質的所有面向。

## C 指標指南與延伸結果

### C.1 探索性測量

另外五個元件是在 40 首發展歌曲上選擇或修訂。它們仍是可用的研究假設，但主文不把它們視為已通過留出檢驗的目標。交互回應比較兩小節樂句，獎勵隔著一個樂句後回返的素材，但不獎勵相鄰複製。停滯-疏離標記長時間重複，或在前後 32 小節內找不到相近內容的活動小節。密度-能量呼應計算小節音符

密度與 mel 能量的等級相關。連打首音 onset 支持度檢查節奏群第一個音符是否接近明顯的 spectral flux。人類譜面距離則在標準化的 32 維特徵空間中，計算到 20 張最近同難度訓練譜的平均距離。

發展組反應說明了各自的範圍。交互回應會回應循環崩解與小節洗牌；停滯-疏離對循環崩解最敏感。連打首音支持度能偵測整譜平移；密度-能量呼應能偵測小節洗牌，但對短暫爆發較弱。人類譜面距離能標出多種分布偏離，卻無法判斷不尋常的譜面是品質

不佳還是具有創意。因此，這些輸出只作為探索性監測訊號，而不是核心獎勵。

## C.2 代理量診斷

常見模式改寫的結果不是由同一個 LM 同時改寫與評分造成。用一個 LM 選擇改寫，再用另一個分開擬合的 LM 評分時，perplexity 仍從 9.44 降到 6.04 (−36%)。把 LM loss 轉成對稱範圍分數也無法抓到最大改寫強度：留出變化為 +0.021，nominal 95% 區間為  $[-0.034, 0.077]$ 。4-gram 軸補上了缺少的讀數。循環崩解時，集合層級 Self-BLEU 從 0.845 上升到 0.898，也記錄到多樣性的流失。

圖 6 將各構念連結至所需輸入、代表性輸出與目前最強的證據；其中的證據標籤區分具留出擾動檢驗的輸出，以及由發展組分析支持的元件。

圖 7 顯示目標擾動可能同時影響多個分數家族，因此這些測量應以剖面方式解讀，而非視為彼此可交換的孤立讀數。



圖 6: 指標與構念對照指南。每個 panel 提出一項評估問題，圖示相關訊號，列出代表性輸出，並標示目前最強的證據。「留出子集」表示只有表 1 中具名的輸出具有留出擾動證據。典型性描述相對同難度人類範圍的偏離。




圖 7: 14 個非冗餘的校準後只讀譜面分數，對各擾動在發展組最大強度下的反應。各格涵蓋範圍典型性分數與單側檢查。紅色表示分數下降、藍色表示上升；數值以人類參照譜的標準差為單位，截斷於  $\pm 4$ 。黑框標示在發展組選出的目標列，不代表統計顯著性。矩陣同時顯示目標敏感度與跨家族耦合。

### C.3 公開系統剖面

我們把這套剖面用在 40 首發展歌曲上的五個公開生成器。Mapperatorinator v32 [17] 與 TaikoNation [2] 會產生太鼓音符類型。DDC 的 onset 管線 [1]、GenéLive! 的公開 timing 設定 [3] 與 AutoOsu [18] 只進入適用的

時值與音訊呼應讀數。我們使用公開推論設定，未在本語料上訓練或微調。這些剖面只示範解讀方式，不是留出指標檢驗，也不是生成器排行榜。

兩個太鼓生成器的容差內音符中位比例相近，但相鄰間隔誤差與整譜相位偏移不同。這正是整譜平移測試揭露的局部與全局差異。依難度校準又顯示另一




圖 8: 40 首發展歌曲上的時值剖面。堆疊長條分開呈現局部對齊音符、時值尾部與未配對音符；右側顯示逐譜差異。平均容差內比例相近的系統，仍可能有不同尾部，因此單一時值平均無法指出失敗原因。




圖 9: 人類譜與兩個能產生太鼓音符類型的生成器之分開讀數。每欄保留自己的意思；矩陣是診斷剖面，不是總分。

個模式：Mapperatorinator 在較簡單 course 的音符率超出人類範圍最多，但時值剖面並未隨難度呈現相同變化。可用的結論是 course 不匹配，不是系統在高難度全面變好。




圖 10: Mapperatorinator 在配對發展譜上的探索性難度剖面。Easy 至 Oni 各含 40 個歌曲–course 配對，Ura 含 10 個。點為中位數，豎線跨第 10 至 90 百分位。生成密度會隨 course 難度提高而接近人類參照，時值卻沒有相同趨勢；這支持 course 不匹配的解讀，而非高難度下的全面改善。

## D 釋出材料

程式碼、評估紀錄與繪圖程式公開於 <https://github.com/JacobLinCool/ChartGenEval>。

## 參考文獻

- [1] C. Donahue, Z. C. Lipton, and J. McAuley, “Dance dance convolution,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, D. Precup and Y. W. Teh, Eds., vol. 70. Sydney, Australia: PMLR, Aug. 2017, pp. 1039–1048. [Online]. Available: <https://proceedings.mlr.press/v70/donahue17a.html>
- [2] E. Halina and M. Guzdial, “TaikoNation: Patterning-focused chart generation for rhythm action games,” in *The 16th International Conference on the Foundations of Digital Games (FDG) 2021*, ser. FDG ’21. New York, NY, USA: Association for Computing Machinery, Aug. 2021, pp. 1–10. [Online]. Available: <https://doi.org/10.1145/3472538.3472589>
- [3] A. Takada, D. Yamazaki, Y. Yoshida, N. Ganbat, T. Shimotomai, N. Hamada, L. Liu, T. Yamamoto, and D. Sakurai, “Genélive! generating rhythm actions in Love Live!” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 4, pp. 5266–5275, Jun. 2023. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/25657>
- [4] J. Hanzen, E. Halina, and M. Guzdial, “Time-based chart partitioning: Improving local coherency in rhythm game chart generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 21, no. 1, pp. 43–51, Nov. 2025. [Online]. Available: <https://ojs.aaai.org/index.php/AIIDE/article/view/36808>
- [5] J. Li, M. Galley, C. Brockett, J. Gao, and B. Dolan, “A diversity-promoting objective function for neural conversation models,” in *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, K. Knight, A. Nenkova, and O. Rambow, Eds. San Diego, California: Association for Computational Linguistics, Jun. 2016, pp. 110–119. [Online]. Available: <https://aclanthology.org/N16-1014/>
- [6] Y. Zhu, S. Lu, L. Zheng, J. Guo, W. Zhang, J. Wang, and Y. Yu, “Txygen: A benchmarking platform for text generation models,” in *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, ser. SIGIR ’18. New York, NY, USA: Association for Computing Machinery, Jun. 2018, pp. 1097–1100. [Online]. Available: <https://doi.org/10.1145/3209978.3210080>
- [7] L.-C. Yang and A. Lerch, “On the evaluation of generative models in music,” *Neural Computing and Applications*, vol. 32, no. 9, pp. 4773–4784, 2020. [Online]. Available: <https://doi.org/10.1007/s00521-018-3849-7>
- [8] H.-W. Dong, K. Chen, J. McAuley, and T. Berg-Kirkpatrick, “MusPy: A toolkit for symbolic music generation,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 101–108. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000187.pdf>

- [9] S.-L. Wu and Y.-H. Yang, “The jazz transformer on the front line: Exploring the shortcomings of AI-composed music through quantitative measures,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 142–149. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000339.pdf>
- [10] M. Gover and O. Zewi, “Music translation: Generating piano arrangements in different playing levels,” in *Proceedings of the 23rd International Society for Music Information Retrieval Conference (ISMIR 2022)*, Bengaluru, India, Dec. 2022, pp. 36–43. [Online]. Available: <https://archives.ismir.net/ismir2022/paper/000003.pdf>
- [11] J. Wang, W. Huang, and X. Li, “Mania archetype: Chart generation for rhythm action games with human factors,” in *Human Factors in Virtual Environments and Game Design*, vol. 137. AHFE Open Access, 2024, pp. 175–185. [Online]. Available: <https://doi.org/10.54941/ahfe1005000>
- [12] M. Plasser, S. Peter, and G. Widmer, “Discrete diffusion probabilistic models for symbolic music generation,” in *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*. International Joint Conferences on Artificial Intelligence Organization, Aug. 2023, pp. 5842–5850. [Online]. Available: <https://www.ijcai.org/proceedings/2023/648>
- [13] J. Retkowski, J. Stepniak, and M. Modrzejewski, “Fréchet music distance: A metric for generative symbolic music evaluation,” *arXiv preprint arXiv:2412.07948*, Jan. 2025. [Online]. Available: <https://arxiv.org/abs/2412.07948>
- [14] J. Opria, “STRUM: A spectral transcription and rhythm understanding model for end-to-end generation of playable rhythm-game charts,” *arXiv preprint arXiv:2605.12135*, May 2026. [Online]. Available: <https://arxiv.org/abs/2605.12135>
- [15] A. Friberg and J. Sundberg, “Time discrimination in a monotonic, isochronous sequence,” *The Journal of the Acoustical Society of America*, vol. 98, no. 5, pp. 2524–2531, Nov. 1995. [Online]. Available: <https://doi.org/10.1121/1.413218>
- [16] L. Theis, A. van den Oord, and M. Bethge, “A note on the evaluation of generative models,” in *4th International Conference on Learning Representations (ICLR 2016), Conference Track Proceedings*, San Juan, Puerto Rico, May 2016. [Online]. Available: <https://arxiv.org/abs/1511.01844>
- [17] O. Schipper, “Mapperatorinator: An AI framework for generating and moddingosu! beatmaps for all gamemodes from spectrogram inputs,” GitHub repository, May 2026, version 32.0.0; MIT-licensed software release. [Online]. Available: <https://github.com/OliBomby/Mapperatorinator/releases/tag/v32.0.0>
- [18] S. Lee and D. Jeong, “AutoOsu: Audio-aware action generation for rhythm games,” Late-Breaking Demo at ISMIR 2023, 2023, project page: <https://issyun.github.io/autoosu/>; public source repository: <https://github.com/issyun/AutoOsu>. [Online]. Available: [https://ismir2023program.ismir.net/lbd\\_319.html](https://ismir2023program.ismir.net/lbd_319.html)