

ChartGenEval：節奏遊戲譜面生成的多維度指標套件

Jhen-Ke Lin

國立陽明交通大學

jacob.cs14@nycu.edu.tw

本文為英文版（paper.tex，v6）之中文對照；正式版本以英文版為準。



圖 1：ChartGenEval 的六個評估維度。ChartGenEval 將譜面評估整理為六個彼此區分的问题，分屬音樂契合度與遊玩相關特性；每個維度保留各自的解讀。

摘要

節奏遊戲譜面必須貼合音樂並具備良好的遊玩特性，但同一首歌曲可以容納多種有效的音符序列。因此，與單一官方譜面的一致度會混淆有效替代方案與實際錯誤。我們提出 ChartGenEval，一套六維度指標套件：它只使用配對官方譜面中由作者編定的時值圖，從不以其中的音符位置作為目標。其整譜格線相位偏移能以零中位誤差回收注入的 15–60 ms 平移，而所有主要只讀譜面輸出的變化都小於人類譜標準差的 0.03 倍。

ChartGenEval 將此時值剖面與另外五個較高層次維度並列報告：音符序列、重複與形式、音樂呼應、與同難度人類譜的距離，以及難度與可玩性限制。各維度維持分開，不合成整體總分。九組非冗餘的擾動–測量配對，在 80 個留出歌曲群組上皆符合預先指定的敏感度與不變性準則；32 項具範圍控制亦全數通過。壓力測試也顯示，孤立代理量可能造成誤導：向常見模式改寫使語言模型 perplexity 下降 37%，循環崩解則使自相似度上升 62%。另五項元件目前具有發展組證據，以玩家判斷為效標的效度仍待建立。我們於 <https://github.com/JacobLinCool/ChartGenEval> 釋出實作、校準值、受控擾動程序與逐譜紀錄。五個公開生成器的描述性剖面可區分單一聚合分數會掩蓋的時值偏離與難度特定偏離。

1 引言

節奏遊戲的自動譜面生成——把音訊映射為可遊玩的定時、定型音符序列——已從 onset 偵測管線進展到條件式序列模型 [1–4]。評估方法卻未同步發展。譜面規定玩家何時做什麼，因此同時回應音樂與玩家兩端。我們以兩項要求組織評估。音樂貼合關注音符是否共享歌曲的時間結構，以及譜面活動是否跟隨音樂起伏；遊玩相關特性則包括可學習的模式、帶變化的重複，以及與指定難度相稱的要求。譜面是一項設計作品，多種音符序列都可能滿足這些要求。

既有方法回答了有用但局部的問題。主流評估——與單一官方譜面比較的配置 F1——量化的是重建程度：有效的替代方案會像缺陷一樣降低重合度，歌曲沒有參照譜時也無法比較。最佳化一致度因此獎勵複製官方答案，並懲罰使製譜成為設計問題的那些差異。語言模型 (LM) 似然量化模型適配度；分佈與自相似度統計描述生成材料；玩家或專家研究則建立系統層級的體驗。這些方法各自回答不同問題，聚合後反而會隱藏其中的權衡。

音符選擇可以自由，時值關係仍需獨立評估。傳統格線式節奏遊戲譜面以歌曲的音樂時間框架組織音符；我們將音樂貼合的這一部分操作化為相對外部格線的對齊。配對官方譜面只提供作者編定的小節、拍號與速度圖，不以音符位置作為目標。這項拆分保留音符選擇的自由，同時揭露只看間隔與音符類型的統計量無法觀察的整譜平移。本文提出的格線相位偏移能回收 15–60 ms 的注入平移，而所有主要只讀譜面測量都錯過這些平移。

ChartGenEval 將時值剖面與五個較高層次維度並列報告：音符序列、重複與形式、音樂呼應、與同難度人類譜的距離，以及難度與限制。有些輸出是原始描述，有些衡量相對同難度人類範圍的雙側偏離，另一些則是單側可行性檢查。這些角色分開解讀，套件不定義通用總分。

受控擾動提供敏感度證據。我們從人類譜出發，施加一項具有劑量控制、旨在削弱特定性質的轉換，再檢查目標測量是否作出反應，同時要求具範圍控制保持不變。九種轉換涵蓋密集時值抖動、稀疏時值錯誤、整譜平移、音符類型置換、循環崩解、常見模式改寫、音符率縮放、爆發插入與小節順序洗牌。我們先在 40 首發展歌曲上選擇與修訂候選測量，再於 80 個留出歌曲群組上評估十組預先指定的擾動–測量配對。所有目標與控制準則均獲滿足；其中一組配對在代數上等價，因此留下九項非冗餘檢驗 (§4.1)。發展組壓力測試進一步顯示，LM perplexity 可能偏好常見模式改寫，自相似度可能偏好循環崩解，而只讀譜面測量無法察覺固定的譜面–音訊平移。

我們的貢獻如下：

1. 一套具有明確證據範圍的指標剖面。ChartGenEval 把時值錨定到歌曲，同時讓五個較高層次維度與單側可行性檢查維持分開。每項輸出皆有明確的輸入、角色與證據基礎。
2. 受控擾動證據。九種具劑量控制的擾動，產生九項非冗餘的留出檢驗，檢查目標反應與具範圍不變性。同一設計亦揭露代理量方向反轉，以及只讀譜面測量對整體平移的盲點。
3. 譜面專用測量與系統剖面。套件加入格線相位偏移，以及五項處於發展階段、衡量譜面-音訊呼應、長程結構與同難度人類譜距離的元件。描述性地施用於五個公開生成器後，剖面可區分時值、序列、密度與難度特定偏離。

我們於 <https://github.com/JacobLinCool/ChartGenEval> 釋出實作、受控擾動程序、校準值與逐譜紀錄。

2 相關研究

參照譜一致度。DDC 與 GenéLive! 對預測音符位置報告 F-score，TCP 則報告 onset、onset-plus-type F1 與局部 pattern recall [1, 3, 4]。其容差與聚合方式各異：DDC 使用 ± 20 ms，GenéLive! 使用 ± 50 ms，TCP 則以小節比例定義容差。TaikoNation 改以 23 ms 二元 frame 與 pattern space 比較 [2]。這些都是重建估計量，承繼 §1 所述的單一參照限制。

無配對與人類錨定評估。DDC 以 LM perplexity 與 token accuracy 評估留出資料上的模型適配度 [1]。符號音樂與文字生成研究則提供多樣性、特徵分佈、自相似度與集合層級重複統計 [5–9]。人類研究回答另一個問題：MuTE 以專家評分驗證參照對齊的鋼琴編曲測量 [10]；GenéLive! 報告專業部署回饋 [3]；Mania Archetype 則結合參照相似度與八位資深玩家評分 [11]。ChartGenEval 提供這類人類研究可進一步採用的自動測量與擾動敏感度證據。

指標壓力測試與時值。SCHmUBERT 建構非音樂性的 piano roll，卻能匹配逐 frame 自相似統計 [12]。Fréchet Music Distance 以音高與力度擾動測試，但仍是集合層級的 embedding 距離 [13]。STRUM 在逐歌搜尋整體偏移後報告參照 onset F1 [14]；ChartGenEval 則把整譜格線相位偏移作為譜面層級測量，且不以參照音符作為目標。我們的 6 ms 時值容差以時間辨別研究為依據 [15, 16] (§3.4)。

3 方法

3.1 ChartGenEval 指標套件

ChartGenEval 將測量設計與敏感度測試分開。套件先界定每項測量的構念、必要輸入、輸出與解讀角色，再以受控擾動檢查目標測量是否回應特定變化，同時要求具範圍控制保持不變（圖 2）。表 1 區分本文提出的測量與既有譜面統計量的改編版本，並列出每一角色在本研究中獲得的最強證據。

本文提出的測量針對單一譜面統計量留下的缺口設計。整譜格線相位偏移在固定的小節、拍與八分

音符錨點上搜尋 -250 至 $+250$ ms 的平移量。為檢查活動是否跟隨音樂起伏，密度-能量呼應在作者編定的小節視窗內，計算每秒打擊數與線性 mel 能量的 Spearman 相關。可用視窗少於八個，或歌曲能量的第 90 與第 10 百分位差小於其中位數的 5% 時，這項測量記為不可用。連打首音 onset 支持度是節奏群首中，在三個 mel frames（約 ± 35 ms）內的最大 spectral flux 達到該歌曲第 60 百分位門檻者所占比例。相鄰 onset 的間隔至少為 0.25 s 時才開始新群組，以免密集連打主導分母。

對長程結構而言，交互回應把譜面依十六分音符位置切成兩小節樂句。具一個位置容差、經機率校正的節奏相似度，乘上經機率校正的音色一致度。若 $S(i, j)$ 表示這個乘積，分數就是 $S(i, i+2)[1 - S(i, i+1)]$ 的樂句平均：素材隔著中間樂句回返，但相鄰的複製式重複不會得到獎勵。

停滯-疏離代理量使用活動小節的節奏與音色 fingerprints。若某小節是連續相似度 $\geq .8$ 序列中的第四個或之後成員，或其每個可用的 16 音符音色視窗都呈現週期不超過四的精確循環，便標為停滯。若前後 32 小節內都沒有相似度至少 .75 的小節，便標為疏離。原始輸出是兩類集合聯集占有活動小節的比例。我們只把它解讀為結構描述；玩家是否感到無聊仍需玩家證據。最後，人類譜差距以 32 個音符間隔、音符類型、密度與多樣性特徵表示每張譜。特徵依難度標準化，原始差距 g 是到同難度 20 張最近訓練譜的平均歐氏距離。有界的顯示分數為 $\exp(-g/a)$ ，其中 a 是該 course leave-one-out 差距的第 90 百分位。表徵本身為譜面專用，其中的 entropy、bigram 與最近鄰基礎量則是既有統計方法。

3.2 資料與時值參照

我們使用自網路社群資源蒐集的 taiko 風格譜面檔與對應音訊；譜面檔轉錄官方難度 course，並作為人類參照譜。由於譜面與音訊可能受版權保護，語料本身不隨本文發布；釋出材料包含衍生校準統計與逐譜紀錄。來源紀錄依歌曲合併為群組，不一致的來源對映予以排除。訓練集包含 924 筆來源紀錄、813 個歌曲群組與 3,880 張各難度譜面，用於擬合校準值與 LM。測試集的 140 筆來源紀錄形成 120 個歌曲群組。當中 40 組包含各可得難度的 170 張人類譜，構成指標與擾動設計、圖表及系統剖面使用的發展組；其餘 80 組構成留出組，在測量、擾動與評估準則的開發期間均未檢視。

另五項本文提出的元件是在發展組上選擇與修訂，因此相關證據仍屬探索性。附錄 A 記錄資料組建構方式與完整分析規格。

時值需要外部的歌曲時值參照。主要格線使用配對官方譜面檔中，由作者編定的逐小節時間戳、拍號與速度中繼資料；官方譜面的音符時間與類型從不作為目標。換言之，官方檔案提供的是時值圖，不是唯一正確的音符序列。這保留時值圖中精確的小節結構，也讓生成譜能在同一音樂時間框架內採取不同而有效的音符設計。我們不使用生成譜自行宣告的格線，避免讓生成器定義自己的參照。

作者編定時值圖不可得時，我們另以音訊估計 downbeat 作為發展階段的替代方案。40 首發展歌曲中，有 39 首的估計節拍週期與中繼資料週期相差不超過 2%；其餘一首相差 2.39%。絕對偏移使用作者




圖 2: 受控擾動驗證。我們施加三種強度的單一目標變化，測量目標反應，並檢驗具範圍不變性。六種測量角色回答不同問題，因此某項輸出的有利移動，無法補償未被捕捉的時值、結構或可行性問題。

構念	主要輸出與解讀	來源	證據基礎
時值	格線容差內比例與殘差尾部；整譜格線相位偏移	本文提出的譜面對格線剖面	使用作者編定格線的 C1、C1s、C2 留出檢驗
音符序列	LM loss 作為描述；未見轉移懲罰作為單側熟悉度檢查	改編的 n -gram 統計	C3 留出檢驗（轉移熟悉度）
重複與形式	4-gram 典型性；ABAB 交互回應；停滯-疏離代理量	改編的 4-gram 分數；兩項本文提出的測量	C4、C5、C8 留出檢驗（單一 4-gram 軸）；新測量僅有發展組證據
音樂呼應	小節層級密度-能量等級相關；連打首音 onset 支持度	兩項本文提出的測量	僅有發展組證據
人類譜距離	32 維譜面表徵中，到 20 張最近訓練譜的平均距離	本文提出的譜面專用實例	僅有發展組證據
難度與限制	密度與負荷典型性；過載與密度尖峰限制	改編統計量；本文提出的校準	C6、C7 留出檢驗（密度典型性、尖峰限制）

表 1: ChartGenEval 的構念、來源與證據邊界。各構念所需的時值、音訊、格線或參照錨點，見方法一節 (§3.2、§3.3)。「本文提出」表示操作化由本文界定，其中的基礎統計量本身可能已有既有來源。留出證據只適用於表中具名輸出；僅有發展組證據的元件是在 40 首發展歌曲上選擇與修訂。任何證據類別都不代表已建立以玩家判斷為效標的效度。

編定格線報告，其小節相位直接來自時值圖。只有具作者編定時值圖的 course 才納入留出時值分析；其餘 course 的時值測量記為不可用。

3.3 測量角色與難度校準

每張譜都是定時、定型的音符序列。我們依圖 1 的六個問題組織原始測量，並對應 §1 的兩項要求。音樂貼合關注所聽與所打的一致，因此時值與音樂呼應需要歌曲；其餘四組不需音訊，用來描述遊玩特性，其中本文提出的結構測量另需節拍格線。改編的譜面內部基礎量包括平滑化 trigram LM、未見轉移率、音符率、局部密度、短間隔負荷、entropy，以及獨特或重複的 4-grams。我們保留 trigram 負對數似然 (NLL) 作為 LM 適配度描述；perplexity 是其指數。我們另把 NLL 轉換為依難度條件化的範圍分數，稱為 *pattern-IC* 典型性。未見轉移率則提供單側的轉移熟悉度檢查：訓練語料中未見的 trigram，代表對語料而言不熟悉，不代表語義上無效。本文提出的結構、音訊呼應、時值與人類譜差距測量已在 §3.1 定義。

我們把選定特徵轉成同難度範圍分數。對每個 course 與選定特徵，令 l, u 分別為訓練譜的第 10、90 百分位， $h = \max((u - l)/2, 10^{-9})$ 為受保護的半範圍

寬。兩側使用同一尺度：

$$d(x) = \begin{cases} (l - x)/h, & x < l, \\ 0, & l \leq x \leq u, \\ (x - u)/h, & x > u, \end{cases} \quad (1)$$

$$s(x) = \frac{1}{1 + d(x)^2}.$$

因此範圍內得 1，向下與向上等距偏離得到相同分數。我們同時保留帶號距離，使大幅偏離不會塌縮到同一個近零分數。

這個分數衡量譜面對指定難度而言有多不尋常；它本身不判定譜面品質。有些測量具有明確的不可欲方向，例如超出難度相對限制的過度負荷；它們使用另行具名的單側分數。轉移熟悉度相對訓練語料同樣是單側的，但不意味語義上無效。沒有指定校準的同族測量保留為原始描述。entropy、密度與重複都沒有通用方向：每一項都可能過低或過高。受控擾動顯示，目標變化往往會把這些值推出人類範圍；不尋常但仍可玩且貼合音樂的譜面，仍可能反映創意選擇 (§5)。

我們依各結果的角色與證據基礎加以使用。可玩性限制維持為分開且不可補償的可行性檢查。發展組的人類譜中，音符率、短間隔與密度尖峰檢查分別有

88%、89% 與 97% 得分至少 0.99。整體平移估計等數值則維持描述性。公開介面分開回傳具名測量與檢查。

3.4 對歌曲測量時值

我們把低於 6 ms 的格線偏差視為容差內，其尺度取自己發表的短間隔恰可覺差 [15]。更大的誤差分三個範圍報告：超過 6、12、18 ms。相鄰音符間隔另以 $\max(6 \text{ ms}, 2.5\% \times \text{IOI})$ 的容差比較。每個音符被計為容差內、超過三個範圍之一，或未配對。未配對的生成音符留在分母中，因此新增離格音符會降低容差內比例。此量沒有參照音符 recall 項，因此刪除未配對的生成音符可能提高比例；我們把它與音符數和同難度密度一併解讀。分析先對每張譜摘要，再跨譜報告中位數與尾部。

最近格點配對可能錯過恆定平移（圖 3）。在密格線上，每個被平移的音符可能只是與另一個鄰近格點配對，因此我們改對整張譜估計單一偏移。對 -250 至 +250 ms 間的每個候選，我們測量多少音符與參照小節內的固定細分對齊，再選出一致性最強的偏移。作者編定格線的小節來自官方譜面的時值圖，而非其音符序列；音訊估計格線的小節則由音訊 downbeat 推估。合併小節、拍與八分音符細分可消解多數週期性平手；殘餘平手取最小幅度偏移。兩種時值摘要都必須有上述其中一種外部格線；作者編定時值圖與音訊估計格線皆不可得時，時值結果記為不可用。BPM 只提供週期、不提供相位，因此不足以作為時值參照。

3.5 受控擾動與判定準則

發展組反應矩陣屬描述性分析。它報告最大劑量的標準化變化，以及逐譜淨方向：相對各自原譜上升的譜面比例減去下降比例。完整的發展組計算與 C5 的獨立 LM 檢查見附錄 A。

我們在 80 個留出歌曲群組上評估十列預先指定的擾動-測量配對。五個確定性擾動複本先在每張譜、每個劑量內平均，各 course 再於歌曲內平均，因此歌曲是推論單位。每項檢驗使用定向後的劑量相關，以及最大劑量減 sham 對比。我們計算歌曲群組 bootstrap 區間，並對十列套用 Bonferroni 校正的 99.5% 區間。若至少 72 首歌曲可評、所有具範圍不變性控制均通過，且兩個調整後上界皆低於零，該反應即符合準則。完整分析規格與來源查核記錄於附錄 A。

各項控制與對應測量家族所主張的不變性一致，包括精確重算、音符與格線共同平移、時值與密度測量使用的 Don-Ka 音色雙射，以及只讀譜面測量使用的整譜平移。必要控制若未通過，該目標反應便不能計為受到支持。

3.6 受評系統

我們評估五個公開生成器，涵蓋三種音符格式：太鼓音符類型、僅含時值的 onset 串流，以及 osu! 位置型物件。兩個系統產生太鼓音符類型：Mapperatorinator v32 [17] 是社群開發、採 MIT 授權的多模式 osu! beatmap 生成框架，本研究以 taiko 模式評估；另一個是 FDG 發表的 TaikoNation [2]，我們依作者公開研究

repository 重現¹。另外三個系統只進入時值與音樂呼應測量：Dance Dance Convolution 的 onset 管線 (dd-conset) [1]、GenéLive! 的公開 timing-only 配置 [3]，以及以 osu! 難度為目標的生成器 AutoOsu [18]。全部系統都在其公開推論配置下，從音訊為同一批 40 首發展歌曲製譜。本研究未在此語料上訓練或微調這些系統，但這些商業歌曲與各系統訓練資料的重疊無法排除 (§6)。course 對映在釋出配置中明確指定：Mapperatorinator 使用相應的太鼓 course；GenéLive 的 Beginner、Easy、Medium、Hard、Challenge 設定分別對映到 Easy、Normal、Hard、Oni、Ura，歌曲無 Ura 譜時，Challenge 以 Oni 為參照 course；單一設定系統則使用指定的 Oni 參照。同一音符格式共用轉換至評估事件串流的程序 (§4.5)。同批歌曲的人類譜提供參照列。依難度生成的系統對每個可得 course 各產生一張譜（170 或 200 張）；其餘系統每首歌產生一張（40 張）。我們將這些剖面報告為描述性的發展組分析。

4 結果

4.1 九項有效檢驗符合留出準則

十列預先指定的配對皆符合兩項反應準則，32 項具範圍控制全數通過，而且每項分析都保留 80 個歌曲群組（表 3）。兩列 C5 在代數上等價，因此結果代表橫跨七個有效輸出軸的九組非冗餘擾動-測量配對。

32 項控制皆精確維持不變。C1s 保留 332 個完整 course，C8 保留 330 個，其餘配對各保留 333 個。樣本數與排除原因見附錄 A。

C5 只提供一個有效軸。重複 4-gram rate 正好等於一減 unique 4-gram rate，因此兩者的鏡像對稱範圍分數，除浮點捨入誤差外完全相同。預先指定的兩個 C5 輸出名稱不能視為彼此獨立的佐證；C5 支持的是單一有效 4-gram 重複 / 唯一性反應。

4.2 外部時間可偵測譜面-音訊平移

一張譜的密度、模式與音符類型可以看似合理，同時相對音樂偏晚。C2 將每個音符平移 15、30 或 60 ms。在發展組上，沒有任何主要只讀譜面輸出的變化超過人類標準差的 0.03 倍，因為只看間隔與類型的測量對共同平移保持不變。

最近格點配對也會錯過平移：密格線可能把每個被平移的音符配到另一個鄰近細分點。格線相位偏移搜尋則從兩種參照來源都回收 15.00、30.00 與 60.00 ms 的中位平移。每個來源、每個平移量下，至少 169/170 張譜落在注入值的 3 ms 內。連打首音 onset 支持度也會在音符 onset 處作出反應（各強度淨方向 -0.74 至 -0.88），並在音符時間保留時保持不變。密集時值抖動下，每張譜在每個強度的 6 ms 內音符比例都下降；在 ± 10 ms 時，容差外比例的實測中位數為 0.40，符合 $P(|U(-10, 10)| > 6) = 0.4$ 。

稀疏錯誤需要尾部敏感的讀數。在 C1s 下，最近格點會重新配對多數被移動音符，因此平均時值誤差的跨譜中位數維持為零。時值誤差 p99 在留出檢驗中作出反應；音符序列 LM 也會改變，因為移動一個音符

¹TaikoNation repository 未聲明軟體授權。釋出材料包含來源與衍生指標紀錄，不含 TaikoNation 程式碼、checkpoint、輸入素材或生成譜資料。




圖 3: 為何時值需要整譜估計。左: 最近格點配對可能把平移後的音符配到不同細分點, 因而報出很小的局部誤差。右: 我們測試候選的整譜偏移; 圖中的示意一致性曲線以最高點找回注入的 +60 ms 平移。格線在評估生成譜面之前即已固定。

受控擾動 (強度)	改變的性質	預先指定的反應
C1 時值抖動 ($\pm 10/20/30$ ms)	音符時值	時值容差內比例 $\downarrow$
C1s 稀疏時值錯誤 (名目 0.5/1/2%, ± 60 ms)	少數音符時間	絕對時值誤差 p99 $\uparrow$
C2 整體平移 (+15/30/60 ms)	譜面-音訊對齊	絕對格線相位偏移 $\uparrow$
C3 音符類型置換 ($p=0.2/0.4/0.8$)	局部轉移	轉移熟悉度 $\downarrow$
C4 循環崩解 ($p=0.3/0.6/1$)	重複與形式	4-gram 典型性 $\downarrow$
C5 常見模式改寫 ($p=0.3/0.6/1$)	模式多樣性	4-gram 典型性 $\downarrow$ (單一有效軸)
C6 音符率縮放 ($\times 0.5/1.5/2$)	難度適配	音符率典型性 $\downarrow$
C7 爆發插入 (2/4/8 個叢集)	局部過載	密度尖峰限制 $\downarrow$
C8 小節順序洗牌 ($p=0.3/0.6/1$)	全局形式	4-gram 典型性 $\downarrow$

表 2: 受控擾動及其九項非冗餘目標讀數。C3–C5 保留音符時間, C4 與 C6 則保留或控制密度。C5 原先具名的兩個 4-gram 輸出在代數上等價, 因此只計為一個有效軸。pattern-IC 典型性與原始 trigram NLL 保留為不預設方向的次要分析。附錄 B 提供視覺化前後比較與完整轉換規格。

配對	主要反應	Courses	$\bar{\rho}_{\text{dose}}$ [99.5% CI]	$\bar{\Delta}_{\text{max-sham}}$ [99.5% CI]
C1	時值容差內比例	333	-.744 [-.815, -.667]	-.502 [-.558, -.446]
C1s	絕對時值誤差 p99	332	-.234 [-.344, -.134]	-.306 [-.508, -.144] ms
C2	絕對格線相位偏移	333	-.916 [-.981, -.826]	-55.58 [-61.43, -49.83] ms
C3	轉移熟悉度	333	-.800 [-.856, -.737]	-.231 [-.262, -.199]
C4	4-gram 典型性	333	-.445 [-.573, -.312]	-.165 [-.226, -.108]
C5	4-gram 典型性	333	-.358 [-.459, -.258]	-.131 [-.189, -.078]
C6	音符率典型性	333	-.693 [-.784, -.579]	-.582 [-.672, -.483]
C7	密度尖峰限制	333	-.940 [-.950, -.930]	-.619 [-.644, -.593]
C8	4-gram 典型性	330	-.589 [-.728, -.435]	-.224 [-.293, -.156]

表 3: 80 個歌曲群組上的留出結果。定向後數值越大越好, 因此目標敏感度表現為負的劑量相關, 以及負的最大劑量減 sham 對比。九組有效配對皆符合預先指定的準則; 區間為家族校正的 99.5% 歌曲群組 bootstrap 區間。C5 報告兩列代數等價輸出中的一列。

會改變兩個相鄰間隔。密度實質不變, 形式則只有微弱反應。

4.3 目標擾動揭露代理量的有利移動

兩個借用的指標, 在目標擾動下朝名目上較有利的方向移動 (圖 4 左)。Perplexity 偏好常見模式: 發展組人類譜的平均值為 9.44; 向 LM 最常見模式改寫後, perplexity 下降 37% (9.44 $\rightarrow$ 5.98)。Dance Dance Convolution 把 perplexity 作為留出人類譜上的模型適配度 [1]; 若將它移植為生成結果的無參照品質讀數, 「越低越好」的解讀便會偏好改寫後的譜面。這是似然 / 品質背離在譜面層級的實例 [19]。一個 LM 產生改寫、另一個 LM 評分時, 反轉仍然

存在 (9.44 $\rightarrow$ 6.04, -36%)。pattern-IC 範圍分數隨三個劑量上升並移向人類範圍。在留出次要分析中, 其最大劑量變化為 +0.021, nominal 95% 區間為 [-0.034, 0.077]; 原始 trigram NLL 則從 2.087 降至 1.715 (-0.373, [-0.399, -0.346])。因此, 典型性本身無法修正此案例。有效 4-gram 軸 (§4.1) 在發展組上從 0.99 降至 0.87。

自相似度偏好崩解: 以譜面自身最主要的 4-gram 循環取代原譜, 使自相似結構度 [9] 上升 62% (0.0848 $\rightarrow$ 0.1370), 集合層級 Self-BLEU [6] 則從 0.845 上升至 0.898。複製貼上的輸出依構造會更加自相似, 但 4-gram 重複 / 唯一性分數從 0.99 降至 0.83。

另外兩項觀察結果補足論證。方向不穩定: 對 §4.5 兩個公開可得、輸出位於人類語料高 entropy 側的太




圖 4: 一項測量錯過目標變化、另一項測量作出反應的兩個案例。長條顯示相對原譜上升的譜面比例減去下降比例；由淺至深表示發展組上的三個擾動強度（僅為描述性結果，不是把各譜視為獨立樣本的信賴敘述）。左：常見模式改寫使 LM loss 下降、pattern-IC 範圍分數上升，4-gram 重複 / 唯一性軸則往反方向移動（兩個代數等價的輸出名稱只繪一次）。右：稀疏的 ± 60 ms 時值錯誤使平均時值誤差接近零，且多被最近格點重新配對；音符序列 LM 則回應改變後的間隔。

鼓生成器，perplexity 以預期方向區分人類與生成譜 (AUC 0.80)；但 C5 證明相同讀法在低 entropy 側會反轉。若帶號品質指標的方向取決於系統位在人類分佈的哪一側，它便無法支持穩定排名；同難度範圍分數把兩側一致解讀為偏離典型性。C5 顯示該分數為何必須與 4-gram 重複 / 唯一性軸一併閱讀。譜長混淆：在相同系統池上，type-token ratio 與音符數的相關為 $|\rho| = 0.85$ ，distinct-2 為 0.56，範圍分數則至多為 0.28。

這些案例確立了互補性，卻沒有提供聚合權重。單一總分必然嵌入本研究的擾動證據與無玩家設計無法識別的價值判斷。完整的指標-擾動反應矩陣見附錄中的圖 9。

4.4 本文所提元件的發展組證據

表 1 中另五項元件具有描述性的發展組證據。把原譜與三個劑量合併計算的 Spearman 反應，支持彼此不同的操作角色。交互回應在循環崩解與小節洗牌下下降 ($\rho = -.612$ 與 $-.506$)，在時值抖動與整體平移下則幾乎不變 ($-.086$ 與 $-.003$)。停滯-疏離代理量對循環崩解有強烈反應（定向為越大越好後 $\rho = -.924$ ），在時值抖動與整體平移下變化很小 ($-.007$ 與 $+.010$)。這些結果支持結構敏感度；玩家感受到的呼應與無聊仍需玩家證據。

兩項音訊呼應測量捕捉不同時間尺度。連打首音 onset 支持度在整體平移下下降 ($\rho = -.559$)；小節層級密度-能量呼應在一致密度縮放下保持穩定 ($\rho = +.005$)，在小節洗牌下下降 ($\rho = -.386$)。它對爆發插入的反應偏弱 ($\rho = -.092$)，因此其解讀限於小節尺度共變。依難度計算的人類譜差距描述的是聯合特徵分佈：它能標示不同於訓練點雲的特徵組合，卻不把不尋常譜面分類為創意或品質不佳。在 C3-C8 下，其同難度分數的最大劑量淨方向介於 $-.32$ 與 $-.88$ ；整體平移下的中位變化為零。釋出的發展表記錄五項元件對全部九種擾動的反應。

4.5 系統剖面

描述性的系統剖面分開呈現兩種會被單一數字合併的效果：相近的時值摘要比例可能源自不同時值行為，而指定 course 也可能改變只讀譜面測量的解讀。

相似的時值比例可能源自不同原因。在圖 5 中，近乎為一的人類列是以作者編定小節 metadata 作為參照的一致性檢查，不是模型結果。兩個太鼓系統落在 6 ms 內的音符中位比例幾乎相同 (0.59 與 0.58)，其餘時值行為卻不同：Mapperatorinator 有 10% 的相鄰間隔超出相對容差，TaikoNation 則為 41%。格線相位偏移搜尋得到 26 與 55 ms 的中位偏移；最近格點配對對兩者卻都報告不到 1 ms 的 6 ms 容差外平均誤差。TaikoNation 的譜面活動與音訊能量也幾乎無關（相關 -0.003 ），音符落在平均能量的 frame 上。DDC onset 系統在相同音訊上得到 2.5 ms 偏移，可作為共享解碼偏移的控制。與 Mapperatorinator 共用 osu! 轉換路徑的 AutoOsu 讀出 19 ms 中位偏移；不同數值排除了共同轉換常數作為唯一解釋 (§3.6)。

指定 course 會改變讀數。Mapperatorinator 的生成 / 人類音符率比從 Easy、Normal 的 2.15–2.35，降至 Oni 的 1.31 與 Ura 的 1.07（附錄中的圖 10）。其音符率、短間隔與局部模式分數在 Easy 至 Hard 低於 0.5，在 Oni 與 Ura 則接近 1。時值沒有相同趨勢：落在 6 ms 內的中位比例依序為 0.56、0.60、0.59、0.57 與 0.62。因此，證據支持的是難度不匹配，不是高難度下的全面改善。TaikoNation 只有單一設定；在該設定下，音符率與短間隔負荷落在人類範圍，卻有 55% 的 trigrams 未見於依難度訓練的 LM，重複 4-gram rate 為 0.004。這些是不同偏離，不能作為單一總排名的基礎。

5 討論

結果支持的是剖面，而非排名。留出檢驗顯示七個有效輸出軸會對各自的目標擾動作出反應；發展組分析則揭露，孤立測量被解讀為品質分數時，可能出現盲




圖 5: 受評系統在 40 首發展歌曲上的時值，使用作者編定格線。每條顯示落在 6 ms 內、6–12、12–18、18 ms 以上或未配對的平均音符比例； n 為譜面數。右側橫線涵蓋 6 ms 內比例的第 10–90 百分位，圓點標示中位數，倒三角形標示最小值。相近的平均容差內比例，仍可能伴隨不同的時值尾部。

	Timing within 6 ms	Note rate	Short intervals	Familiar transitions	Local patterns	4-gram repetition / uniqueness	overload	density spike	playability
human reference	1.00	1.00	1.00	0.75	1.00	1.00	✓	✓	✓
Mapperatorinator	0.59	0.23	0.36	0.23	0.19	1.00	✓	✓	✗
TaikoNation	0.58	1.00	1.00	0.00	0.01	0.08	✓	✓	✓

圖 6: 人類參照與兩個使用太鼓音符類型的生成器，在發展組上的分開結果。第一欄是音符落在格線 6 ms 內的中位比例；其餘格為 $[0, 1]$ 的校準分數。音符率、短間隔、局部模式與 4-gram 重複 / 唯一性各欄的 1 表示中位數落在人類範圍；轉移熟悉度是單側分數（越大越好），連人類參照也只有 0.75，因為 LM 仍會遇到未見的 trigrams。右側符號以中位閾值 0.5 分開顯示過載、尖峰與可玩性檢查。其他音符格式只出現在時值比較（圖 5）。各欄揭露不同偏離，不合成總分。

點與名目上有利的移動。合併這些維度需要價值判斷與效標證據，而本研究並未提供這兩者。

非典型性必須結合脈絡解讀。受控擾動顯示，目標變化往往會把分數推出同難度人類範圍，但反向推論並不成立：不尋常譜面可能反映創意選擇。時值與可行性檢查有助於解讀這項偏離；當各訊號彼此不一致時，仍需玩家判斷。距離尺度可協助理解大幅偏離：發展組人類譜在序列軸上的最大值為 4.8 個半範圍寬，Mapperatorinator 與 TaikoNation 的中位數則分別為 2.1 與 12。§4.5 的 course 分析示範了多個訊號如何支持具範圍的解讀，而不產生排行榜。

可轉移性取決於測量角色。時值與音樂呼應測量只讀音符時間，因此可直接施用於三種音符格式。序列、形式與距離測量需要目標遊戲的 tokenizer，以及供校準的人類譜；lane、位置或方向 token 都可取代太鼓音符類型。相同的受控擾動設計可檢查哪些反應能轉移到另一款遊戲。位置型遊戲還需要移動成本、手部分配與旋轉等額外檢查。

6 限制

構念效度與擾動涵蓋範圍。受控擾動建立的是對操作性變化的敏感度，不是相對玩家或專家判斷的效標效

度。九種擾動未涵蓋配錯歌曲、刪除音樂上重要的音符，以及刻意離格配置。個別譜面在擾動後也可能移向人類範圍。另五項元件在提出更強的品質主張前，仍需留出證據或玩家證據。最後，預先指定的兩個 C5 輸出名稱在代數上等價；未來研究應改測獨立的結構測量。

語料與系統範圍。人類範圍由單一遊戲語料定義。來源中繼資料沒有 charter 或遊戲版本欄位，且幾乎每首歌的曲風都未標註，因此無法刻畫作者、版本或曲風層級的集中度；釋出的涵蓋紀錄改為呈現各 course 內寬廣的難度與速度跨度（附錄圖 11）。其他音符格式只接受時值與音樂呼應測量，每個公開系統也只以一個公開配置與一個 seed 執行。發展歌曲與系統訓練語料可能重疊，本研究未加以控制。共用路徑比較顯示，單一轉換常數不足以解釋觀察到的所有偏移，但各格式特定的轉換效應仍可能存在。因此，系統結果屬比較性描述。

測量與推論。時值容差內比例會懲罰新增的離格音符，卻沒有參照 recall 項，因此刪除音符可能提高比例；這項測量也需要外部格線。留出時值結果使用作者編定格線，音訊估計替代方案則只有發展組證據。序列 token 包含音符間隔，因此時值與序列反應可能重疊（附錄中的圖 9）。各 course 先在歌曲內平均，因此歌曲是推論單位；同一作者跨歌曲可能造成的依賴尚未建模。確定性的擾動複本在譜內平均，不會形成額外樣本。

7 結論

我們提出 ChartGenEval，一套六維度指標套件。它以配對官方譜面作為作者編定的時值圖，同時排除其中的音符位置，不把它們當成目標。時值與另外五個較高層次維度並列報告；原始描述、雙側典型性與單側可行性檢查保留各自角色，不合成整體分數。

九組非冗餘擾動-測量配對，在 80 個歌曲群組上皆符合留出敏感度與不變性準則。同一研究顯示，只讀譜面測量會錯過整體平移，perplexity 與自相似度則可能在目標擾動下朝名目上有利的方向移動。描述性系統剖面揭露聚合分數會掩蓋的時值、序列、密度與 course 特定偏離。我們於 <https://github.com/JacobLinCool/ChartGenEval> 釋出實作與證據。未來指標可先界定其構念與角色，再證明相應的目標反應與不變性邊界，據此納入此剖面。

倫理聲明

本研究使用 §3.2 所述、自網路來源蒐集的社群轉錄譜面與對應音訊；這些可能受版權保護的材料不隨本文再散布。釋出 artifact 包含測量結果、評估程式碼與來源紀錄，但不包含原始譜面、音訊、個人資料或譜面生成器。更強的評估能力可能降低大量自動產製內容的成本，因此高量部署仍需搭配平台政策與審核機制。

AI 使用聲明

AI 助理在作者指導下用於實驗編排、起草與編輯；所有數字皆由釋出程式碼產生、獨立重算並由作者查核。

A 留出評估協定

A.1 資料組建構與完整性

來源紀錄依 group_id 與音訊 SHA-256 正規化；不一致的別名會在資料組索引前排除。測試集依儲存順序包含 120 個歌曲群組，其中第 0–39 組構成發展組，第 40–119 組構成留出組。在檢視留出結果前，我們先於 manifest 中固定資料集版本、擾動與劑量、目標測量、控制、閾值、校準、執行環境、分析程式碼與來源雜湊。若任何輸入或來源雜湊與紀錄不符，分析即中止。

A.2 複本、完整性與推論單位

每個非零擾動 cell 與控制條件都使用 base seeds 1103、2207、3301、4409 與 5519。複本先在每張譜、每個劑量內平均。course 只有在原譜值、所有目標劑量與複本、具範圍 sham 及必要控制皆可得時才算完整。歌曲至少有一個完整 course 才進入該檢驗；完整 course 再於歌曲內平均。因此，兩個反應統計量的推論單位都是歌曲，而非譜面、course 或複本。確定性的 no-op 與缺失 cell 保留在排除紀錄中。

A.3 具範圍控制與數值不變性

每項保留測量都進行 identity 重算。音符、作者編定格線與時長共同平移 +1 秒，用於檢查對時間原點的不變性。Don-Ka 音色雙射只用於與音色無關的時值與密度測量，不作為 grammar 或形式的控制。60 ms 的 C2 平移則是只讀譜面密度、grammar 與結構測量的 sham。必要控制未通過時，對應目標反應便不能視為受到支持。釋出規格紀錄每項指標的等價容差與 timestamp 捨入規則。只讀譜面的間隔運算使用整數微秒，比最小報告容差細三個數量級。

A.4 區間與判定規則

把輸出定向為越大越好後，第一個統計量是原譜加三個劑量的四種強度，與測量之間的逐譜 Spearman 相關；四個反應全為常數時，敏感度定義為零。第二個統計量是定向後的最大劑量值減去具範圍 sham。點估計取歌曲層級值的平均。我們以 seed 20260712 進行 10,000 次歌曲群組 bootstrap，次要分析報告 nominal 95% 區間，十列主要配對則使用 Bonferroni 校正的 99.5% 區間。若至少 72/80 首歌曲可評、所有控制均通過，且兩個調整後上界皆低於零，該反應即獲支持。調整後下界若為非負，則與預期反應相反；其餘情況視為無法判定。兩列 C5 輸出必須共同符合規則，但其代數等價性只留下單一有效軸。C5 LM 使用完整且依儲存順序排列的訓練集、trigram order 3，以及 $\text{add-}\alpha = 0.05$ 。

A.5 樣本數與排除

留出分析從 333 張譜產生 50,283 筆觀察紀錄。C1s 保留 332 個完整 course，C8 保留 330 個，其餘有效配對皆保留 333 個。32 項控制全數通過，觀察到的最大絕對差異為零。19 個確定性 no-op cell 保留在釋出排除紀錄中。釋出材料保存完整的觀察、約化、排除與來源紀錄。

B 受控擾動規格

170 張譜的發展矩陣在每個非零 cell 使用一個 realization，連同原譜共產生 4,760 張變體。C1s 將譜面 n 個音符中的 $\max(1, \text{round}(np))$ 個平移 ± 60 ms。C3–C5 保留音符時間，C4 與 C6 則保留或控制密度。原始特徵與其衍生分數都在同一批變體上計算，等價量只計一次。C5 由一個 LM 選擇常見模式改寫，再由另一個獨立擬合的 LM 評分；perplexity 反轉仍然存在 ($9.44 \rightarrow 6.04$ ， -36%)。



圖 7: 受控擾動圖譜。藍色表示原譜，橘色表示編輯後的事件。各 panel 呈現一種擾動所改變的性質，並標示其目標測量。C1–C2 針對時值，C3 針對轉移熟悉度，C4–C5 與 C8 針對重複或形式，C6–C7 則針對難度適配與局部負荷。這些編輯隔離了操作性變化，但不涵蓋譜面品質的所有面向。

C 指標指南與延伸結果

下列指南把各構念連結到所需輸入、代表性輸出與目前證據；其後的矩陣則呈現跨家族反應，以及支撐主文具範圍解讀的 course 特定難度模式。



圖 8: 指標與構念對照指南。每個 panel 提出一項評估問題，圖示相關訊號，列出代表性輸出，並標示目前最強的證據。「留出自集」表示只有表 1 中具名的輸出具有留出擾動證據。典型性描述相對同難度人類範圍的偏離；以玩家判斷為效標的效度仍不在目前證據範圍內。




圖 9: 14 個非冗餘的校準後只讀譜面分數，對各擾動在發展組最大強度下的反應。各格涵蓋範圍典型性分數與單側檢查。紅色表示分數下降、藍色表示上升；數值以人類參照譜的標準差為單位，截斷於 ± 4 。黑框標示在發展組選出的目標列，不代表統計顯著性。矩陣同時顯示目標敏感度與跨家族耦合。




圖 10: Mapperatorinator 在配對發展譜上的探索性難度剖面。Easy 至 Oni 各含 40 個歌曲-course 配對，Ura 含 10 個。點為中位數，豎線跨第 10 至 90 百分位。生成密度會隨 course 難度提高而接近人類參照，時值卻沒有相同趨勢；這支持 course 不匹配的解讀，而非高難度下的全面改善。




圖 11: 定義校準範圍的人類參照語料，在來源中繼資料所記錄的兩個維度上的涵蓋。(a) 3,880 張訓練譜中，各 course 的星級計數：每個 course 都橫跨寬廣且逐步位移的難度範圍。(b) 速度直方圖（中位 170 BPM，範圍 65-376）。來源中繼資料沒有 charter 或遊戲版本欄位，且幾乎每首歌的曲風都未標註，因此無法報告作者、版本或曲風層級的集中度 (§6)。

D 可重現性與釋出材料

<https://github.com/JacobLinCool/ChartGenEval> 的釋出材料包含實作、校準值、受控擾動定義、系統條件、逐譜測量、語料涵蓋統計、留出觀察與約

化表、排除紀錄，以及來源 manifests。執行 `python experiments/make_paper_figures.py` 可從版本化紀錄重建論文中的所有圖，包括英文與繁體中文示意圖。

參考文獻

- [1] C. Donahue, Z. C. Lipton, and J. McAuley, “Dance dance convolution,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, D. Precup and Y. W. Teh, Eds., vol. 70. Sydney, Australia: PMLR, Aug. 2017, pp. 1039–1048. [Online]. Available: <https://proceedings.mlr.press/v70/donahue17a.html>
- [2] E. Halina and M. Guzdial, “TaikoNation: Patterning-focused chart generation for rhythm action games,” in *The 16th International Conference on the Foundations of Digital Games (FDG) 2021*, ser. FDG ’21. New York, NY, USA: Association for Computing Machinery, Aug. 2021, pp. 1–10. [Online]. Available: <https://doi.org/10.1145/3472538.3472589>
- [3] A. Takada, D. Yamazaki, Y. Yoshida, N. Ganbat, T. Shimotomai, N. Hamada, L. Liu, T. Yamamoto, and D. Sakurai, “Genélive! generating rhythm actions in Love Live!” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 4, pp. 5266–5275, Jun. 2023. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/25657>
- [4] J. Hanzen, E. Halina, and M. Guzdial, “Time-based chart partitioning: Improving local coherency in rhythm game chart generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 21, no. 1, pp. 43–51, Nov. 2025. [Online]. Available: <https://ojs.aaai.org/index.php/AIIDE/article/view/36808>
- [5] J. Li, M. Galley, C. Brockett, J. Gao, and B. Dolan, “A diversity-promoting objective function for neural conversation models,” in *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, K. Knight, A. Nenkova, and O. Rambow, Eds. San Diego, California: Association for Computational Linguistics, Jun. 2016, pp. 110–119. [Online]. Available: <https://aclanthology.org/N16-1014/>
- [6] Y. Zhu, S. Lu, L. Zheng, J. Guo, W. Zhang, J. Wang, and Y. Yu, “Texygen: A benchmarking platform for text generation models,” in *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, ser. SIGIR ’18. New York, NY, USA: Association for Computing Machinery, Jun. 2018, pp. 1097–1100. [Online]. Available: <https://doi.org/10.1145/3209978.3210080>
- [7] L.-C. Yang and A. Lerch, “On the evaluation of generative models in music,” *Neural Computing*

- and Applications, vol. 32, no. 9, pp. 4773–4784, 2020. [Online]. Available: <https://doi.org/10.1007/s00521-018-3849-7>
- [8] H.-W. Dong, K. Chen, J. McAuley, and T. Berg-Kirkpatrick, “MusPy: A toolkit for symbolic music generation,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 101–108. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000187.pdf>
- [9] S.-L. Wu and Y.-H. Yang, “The jazz transformer on the front line: Exploring the shortcomings of AI-composed music through quantitative measures,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 142–149. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000339.pdf>
- [10] M. Gover and O. Zewi, “Music translation: Generating piano arrangements in different playing levels,” in *Proceedings of the 23rd International Society for Music Information Retrieval Conference (ISMIR 2022)*, Bengaluru, India, Dec. 2022, pp. 36–43. [Online]. Available: <https://archives.ismir.net/ismir2022/paper/000003.pdf>
- [11] J. Wang, W. Huang, and X. Li, “Mania archetype: Chart generation for rhythm action games with human factors,” in *Human Factors in Virtual Environments and Game Design*, vol. 137. AHFE Open Access, 2024, pp. 175–185. [Online]. Available: <https://doi.org/10.54941/ahfe1005000>
- [12] M. Plasser, S. Peter, and G. Widmer, “Discrete diffusion probabilistic models for symbolic music generation,” in *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*. International Joint Conferences on Artificial Intelligence Organization, Aug. 2023, pp. 5842–5850. [Online]. Available: <https://www.ijcai.org/proceedings/2023/648>
- [13] J. Retkowski, J. Stępnia, and M. Modrzejewski, “Fréchet music distance: A metric for generative symbolic music evaluation,” *arXiv preprint arXiv:2412.07948*, Jan. 2025. [Online]. Available: <https://arxiv.org/abs/2412.07948>
- [14] J. Opria, “STRUM: A spectral transcription and rhythm understanding model for end-to-end generation of playable rhythm-game charts,” *arXiv preprint arXiv:2605.12135*, May 2026. [Online]. Available: <https://arxiv.org/abs/2605.12135>
- [15] A. Friberg and J. Sundberg, “Time discrimination in a monotonic, isochronous sequence,” *The Journal of the Acoustical Society of America*, vol. 98, no. 5, pp. 2524–2531, Nov. 1995. [Online]. Available: <https://doi.org/10.1121/1.413218>
- [16] J. London, *Hearing in Time: Psychological Aspects of Musical Meter*, 2nd ed. Oxford University Press, May 2012. [Online]. Available: <https://academic.oup.com/book/9899>
- [17] O. Schipper, “Mapperatorinator: An AI framework for generating and moddingosu! beatmaps for all gamemodes from spectrogram inputs,” GitHub repository, May 2026, version 32.0.0; MIT-licensed software release. [Online]. Available: <https://github.com/OliBomby/Mapperatorinator/releases/tag/v32.0.0>
- [18] S. Lee and D. Jeong, “AutoOsu: Audio-aware action generation for rhythm games,” Late-Breaking Demo at ISMIR 2023, 2023, project page: <https://issyun.github.io/autoosu/>; public source repository: <https://github.com/issyun/AutoOsu>. [Online]. Available: https://ismir2023program.ismir.net/lbd_319.html
- [19] L. Theis, A. van den Oord, and M. Bethge, “A note on the evaluation of generative models,” in *4th International Conference on Learning Representations (ICLR 2016), Conference Track Proceedings*, San Juan, Puerto Rico, May 2016. [Online]. Available: <https://arxiv.org/abs/1511.01844>