

ChartGenEval：節奏遊戲譜面生成的多維度指標套件

Jhen-Ke Lin
國立陽明交通大學

jacob.cs14@nycu.edu.tw

本文為英文版（paper.tex，v6）之中文對照；正式版本以英文版為準。



圖 1：ChartGenEval 的六個評估維度。ChartGenEval 將譜面評估整理為六個彼此區分的问题，分屬音樂契合度與遊玩相關特性；每個維度保留各自的解讀。

摘要

節奏遊戲譜面必須貼合音樂並具備良好的遊玩特性，但同一首歌曲可以容納多種有效的音符序列。因此，與單一官方譜面的一致度會混淆有效替代方案與實際錯誤。我們提出 ChartGenEval，一套六維度指標套件：它只使用配對官方譜面中由作者編定的時值圖，從不以其中的音符位置作為目標。其整譜格線相位偏移對注入的 15、30 與 60 ms 整譜平移，中位估計都與真值一致。相較之下，所有主要只讀譜面輸出的變化都小於人類譜標準差的 0.03 倍。

ChartGenEval 將此時值剖面與另外五個較高層次維度並列報告：音符序列、重複與形式、音樂呼應、與同難度人類譜的距離，以及難度與可玩性限制。各維度維持分開，不合成整體總分。九組非冗餘的擾動-測量配對，在 80 個留出歌曲群組上皆符合預先指定的敏感度與不變性準則；32 項適用的控制檢查亦全數通過。壓力測試也顯示，孤立代理量可能造成誤導：向常見模式改寫使語言模型 perplexity 下降 37%，循環崩解則使自相似度上升 62%。整體而言，這套自動化六維度剖面可支援譜面生成模型的快速比較與迭代。各項輸出也可依角色作為獎勵、限制或監測訊號，用於強化學習等訓練方式。

1 引言

節奏遊戲的自動譜面生成把音訊映射為可遊玩的定時、定型音符序列。相關技術已從 onset 偵測方法進展到條件式序列模型 [1–4]。評估方法卻未同步發展。譜面規定玩家何時做什麼，因此同時回應音樂與玩家兩端。我們以兩項要求組織評估。音樂貼合關注音符是否共享歌曲的時間結構，以及譜面活動是否跟隨音樂起伏；遊玩相關特性則包括可學習的模式、帶變化的重複，以及與指定難度相稱的要求。譜面是一項設計作品，多種音符序列都可能滿足這些要求。

既有方法回答了有用但局部的問題。主流評估採用與單一官方譜面比較的配置 F1，量化的是重建程度：

有效的替代方案會像缺陷一樣降低重合度，歌曲沒有參照譜時也無法比較。最佳化一致性因此獎勵複製官方答案，並懲罰使製譜成為設計問題的那些差異。語言模型 (LM) 似然量化模型適配度；分佈與自相似度統計描述生成材料；玩家或專家研究則建立系統層級的體驗。這些方法各自回答不同問題，聚合後反而會隱藏其中的權衡。

音符選擇可以自由，時值關係仍需獨立評估。傳統格線式節奏遊戲譜面以歌曲的音樂時間框架組織音符；我們以相對外部格線的對齊來測量音樂貼合的這一部分。配對官方譜面只提供作者編定的小節、拍號與速度圖，不以音符位置作為目標。這項拆分保留音符選擇的自由，同時揭露只看間隔與音符類型的統計量無法觀察的整譜平移。本文提出的格線相位偏移對注入的 15、30 與 60 ms 平移都給出正確的中位估計，而所有主要只讀譜面測量幾乎不變。

ChartGenEval 會自動計算六個維度的評估剖面：時值、音符序列、重複與形式、音樂呼應、與同難度人類譜的距離，以及難度與可玩性。各項輸出分為三種用途：模型改進的目標訊號、可行性限制，以及比較模型與找出問題的監測訊號。這些用途分開處理，因此每個維度都保留自己的意義。

受控擾動提供敏感度證據。我們從人類譜出發，施加一項具有劑量控制、旨在削弱特定性質的轉換，再檢查目標測量是否作出反應，同時要求適用的控制檢查保持不變。九種轉換涵蓋密集時值抖動、稀疏時值錯誤、整譜平移、音符類型置換、循環崩解、常見模式改寫、音符率縮放、爆發插入與小節順序洗牌。我們先在 40 首發展歌曲上選擇與修訂候選測量，再於 80 個留出歌曲群組上評估十組預先指定的擾動-測量配對。所有目標與控制準則均獲滿足；其中一組配對在代數上等價，因此留下九項非冗餘檢驗 (§4.1)。發展組壓力測試進一步顯示，LM perplexity 可能偏好常見模式改寫，自相似度可能偏好循環崩解，而只讀譜面測量無法察覺固定的譜面-音訊平移。

我們的貢獻如下：

1. 自動化的六維度回饋。ChartGenEval 分別計算時值、音符序列、重複與形式、音樂呼應、人類譜距離，以及難度與可玩性的訊號。這些訊號可支援模型比較、快速迭代，以及以獎勵為基礎的訓練。
2. 受控擾動證據。九種具劑量控制的擾動，產生九項非冗餘的留出檢驗，檢查目標反應與指定的不變性檢查。同一設計亦揭露代理量方向反轉，以及只讀譜面測量對整體平移的盲點。
3. 譜面專用測量。套件加入格線相位偏移，以及五項處於發展階段、衡量譜面-音訊呼應、長程結構與同難度人類譜距離的元件。

2 相關研究

參照譜一致度。DDC 與 GenéLive! 對預測音符位置報告 F-score，TCP 則報告 onset、onset-plus-type F1 與局部 pattern recall [1, 3, 4]。其容差與聚合方式各異：DDC 使用 ± 20 ms，GenéLive! 使用 ± 50 ms，TCP 則以小節比例定義容差。TaikoNation 改以 23 ms 二元 frame 與 pattern space 比較 [2]。這些都是重建估計量，承繼 §1 所述的單一參照限制。

無配對與人類錨定評估。DDC 以 LM perplexity 與 token accuracy 評估留出資料上的模型適配度 [1]。符號音樂與文字生成研究則提供多樣性、特徵分佈、自相似度與集合層級重複統計 [5–9]。人類研究回答另一個問題：MuTE 以專家評分驗證參照對齊的鋼琴編曲測量 [10]；GenéLive! 報告專業部署回饋 [3]；Mania Archetype 則結合參照相似度與八位資深玩家評分 [11]。ChartGenEval 提供這類人類研究可進一步採用的自動測量與擾動敏感度證據。

指標壓力測試與時值。SCHmUBERT 建構非音樂性的 piano roll，卻能匹配逐 frame 自相似統計 [12]。Fréchet Music Distance 以音高與力度擾動測試，但仍是集合層級的 embedding 距離 [13]。STRUM 在逐歌搜尋整體偏移後報告參照 onset F1 [14]；ChartGenEval 則把整譜格線相位偏移作為譜面層級測量，且不以參照音符作為目標。我們的 6 ms 時值容差以時間辨別研究為依據 [15, 16] (§3.4)。

3 方法

3.1 ChartGenEval 指標套件

ChartGenEval 自動計算六組測量。受控擾動檢查目標測量在不同劑量下的敏感度，適用的控制檢查則確認不變性。表 1 區分本文提出的測量與既有譜面統計量的改編版本，並列出每一角色在本研究中獲得的最強證據。

ChartGenEval 的所有輸出都可自動計算，但用途不同。具有明確方向的輸出可作為獎勵或懲罰，可玩性檢查可作為限制，描述性輸出則可作為監測訊號。強化學習等訓練方式可依任務選擇這些訊號並設定權重。

本文提出的測量針對單一譜面統計量留下的缺口設計。整譜格線相位偏移在固定的小節、拍與八分音符錨點上搜尋 -250 至 $+250$ ms 的平移量。為檢查活動是否跟隨音樂起伏，密度-能量呼應在作者編定

的小節視窗內，計算每秒打擊數與線性 mel 能量的 Spearman 相關。可用視窗少於八個，或歌曲能量的第 90 與第 10 百分位差小於其中位數的 5% 時，這項測量記為不可用。連打首音 onset 支持度是節奏群首中，在三個 mel frames (約 ± 35 ms) 內的最大 spectral flux 達到該歌曲第 60 百分位門檻者所占比例。相鄰 onset 的間隔至少為 0.25 s 時才開始新群組，以免密集連打主導分母。

對長程結構而言，交互回應把譜面依十六分音符位置切成兩小節樂句。具一個位置容差、經機率校正的節奏相似度，乘上經機率校正的音色一致度。若 $S(i, j)$ 表示這個乘積，分數就是 $S(i, i+2)[1 - S(i, i+1)]$ 的樂句平均；素材隔著中間樂句回返，但相鄰的複製式重複不會得到獎勵。

停滯-疏離代理量使用活動小節的節奏與音色 fingerprints。若某小節是連續相似度 $\geq .8$ 序列中的第四個或之後成員，或其每個可用的 16 音符音色視窗都呈現週期不超過四的精確循環，便標為停滯。若前後 32 小節內都沒有相似度至少 .75 的小節，便標為疏離。原始輸出是兩類集合聯集占有活動小節的比例。我們只把它作為結構訊號。最後，人類譜距離以 32 個音符間隔、音符類型、密度與多樣性特徵表示每張譜。特徵依難度標準化，原始距離 g 是到同難度 20 張最近訓練譜的平均歐氏距離。有界的顯示分數為 $\exp(-g/a)$ ，其中 a 是該 course leave-one-out 距離的第 90 百分位。表徵本身為譜面專用，其中的 entropy、bigram 與最近鄰基礎量則是既有統計方法。

3.2 資料與時值參照

我們使用自網路社群資源蒐集的 taiko 風格譜面檔與對應音訊；譜面檔轉錄官方難度 course，並作為人類參照譜。由於譜面與音訊可能受版權保護，語料本身不隨本文發布。來源紀錄依歌曲合併為群組，不一致的來源對映予以排除。訓練集與測試集各有不同用途。訓練集有 924 筆來源紀錄，涵蓋 813 個不重複的歌曲群組與 3,880 張各難度譜面；這些譜用於擬合校準值與 LM。測試集有 140 筆來源紀錄，形成 120 個歌曲群組。前 40 組含 170 張人類譜，作為指標與擾動設計、圖表及系統剖面的發展組；後 80 組含 333 張各難度譜面，作為確認性檢驗的留出組。資料另含 80 個歌曲群組的驗證集；本文報告的分析未使用。發展與留出兩階段的受控擾動分析合計涵蓋全部 120 首測試歌曲：40 首用於發展，80 首用於留出確認。公開系統比較只使用其中 40 首發展歌曲。

另五項本文提出的元件是在發展組上選擇與修訂，因此相關證據仍屬探索性。附錄 A 記錄資料組建構方式與完整分析規格。

時值需要外部的歌曲時值參照。主要格線使用配對官方譜面檔中，由作者編定的逐小節時間戳、拍號與速度中繼資料；官方譜面的音符時間與類型從不作為目標。換言之，官方檔案提供的是時值圖，不是唯一正確的音符序列。這保留時值圖中精確的小節結構，也讓生成譜能在同一音樂時間框架內採取不同而有效的音符設計。我們不使用生成譜自行宣告的格線，避免讓生成器定義自己的參照。

作者編定時值圖不可得時，我們另以音訊估計 downbeat 作為發展階段的替代方案。40 首發展歌曲中，有 39 首的估計節拍週期與中繼資料週期相差不超過 2%；其餘一首相差 2.39%。絕對偏移使用作者

構念	主要輸出與解讀	來源	證據基礎
時值	格線容差內比例與殘差尾部；整譜格線相位偏移	本文提出的譜面對格線剖面	使用作者編定格線的 C1、C1s、C2 留出檢驗
音符序列	LM loss 作為描述；未見轉移懲罰作為單側熟悉度檢查	改編的 n -gram 統計	C3 留出檢驗（轉移熟悉度）
重複與形式	4-gram 典型性；ABAB 交互回應；停滯-疏離代理量	改編的 4-gram 分數；兩項本文提出的測量	C4、C5、C8 留出檢驗（單一 4-gram 軸）；新測量僅有發展組證據
音樂呼應	小節層級密度-能量等級相關；連打首音 onset 支持度	兩項本文提出的測量	僅有發展組證據
人類譜距離	32 維譜面表徵中，到 20 張最近訓練譜的平均距離	本文提出的譜面專用實例	僅有發展組證據
難度與限制	密度與負荷典型性；過載與密度尖峰限制	改編統計量；本文提出的校準	C6、C7 留出檢驗（密度典型性、尖峰限制）

表 1: ChartGenEval 的構念、來源與證據邊界。各構念所需的時值、音訊、格線或參照錨點，見方法一節 (§3.2、§3.3)。「本文提出」表示測量由本文定義，其中的基礎統計量可能已有既有來源。留出證據只適用於表中具名輸出。

編定格線報告，其小節相位直接來自時值圖。只有具作者編定時值圖的 course 才納入留出時值分析；其餘 course 的時值測量記為不可用。

3.3 測量角色與難度校準

每張譜都是定時、定型的音符序列。我們依圖 1 的六個問題組織原始測量，並對應 §1 的兩項要求。音樂貼合關注所聽與所打的一致，因此時值與音樂呼應需要歌曲；其餘四組不需音訊，用來描述遊玩特性，其中本文提出的結構測量另需節拍格線。改編的譜面內部基礎量包括平滑化 trigram LM、未見轉移率、音符率、局部密度、短間隔負荷、entropy，以及獨特或重複的 4-grams。我們保留 trigram 負對數似然 (NLL) 作為 LM 適配度描述；perplexity 是其指數。我們另把 NLL 轉換為依難度條件化的範圍分數，稱為 *pattern-IC* 典型性。未見轉移率則提供單側的轉移熟悉度檢查：訓練語料中未見的 trigram，代表對語料而言不熟悉，不代表語義上無效。本文提出的結構、音訊呼應、時值與人類譜距離測量已在 §3.1 定義。

我們把選定特徵轉成同難度範圍分數。對每個 course 與選定特徵，令 l, u 分別為訓練譜的第 10、90 百分位， $h = \max((u - l)/2, 10^{-9})$ 為受保護的半範圍寬。兩側使用同一尺度：

$$d(x) = \begin{cases} (l - x)/h, & x < l, \\ 0, & l \leq x \leq u, \\ (x - u)/h, & x > u, \end{cases} \quad (1)$$

$$s(x) = \frac{1}{1 + d(x)^2}.$$

因此範圍內得 1，向下與向上等距偏離得到相同分數。我們同時保留帶號距離，使大幅偏離不會塌縮到同一個近零分數。

這個分數衡量譜面對指定難度而言有多不尋常；它本身不判定譜面品質。有些測量具有明確的不可欲方向，例如超出難度相對限制的過度負荷；它們使用另行具名的單側分數。轉移熟悉度相對訓練語料同樣是單側的，但不意味語義上無效。沒有指定校準的同族測量保留為原始描述。entropy、密度與重複都沒有通用方向：每一項都可能過低或過高。受控擾動顯示，

目標變化往往會把這些值推出人類範圍；不尋常但仍可玩且貼合音樂的譜面，仍可能反映創意選擇 (§5)。

可玩性限制維持為分開且不可補償的可行性檢查。發展組的人類譜中，音符率、短間隔與密度尖峰檢查分別有 88%、89% 與 97% 得分至少 0.99。整體平移估計等數值則維持描述性。

3.4 對歌曲測量時值

我們把低於 6 ms 的格線偏差視為容差內，其尺度取自己發表的短間隔恰可覺差 [15]。更大的誤差分三個範圍報告：超過 6、12、18 ms。相鄰音符間隔另以 $\max(6 \text{ ms}, 2.5\% \times \text{IOI})$ 的容差比較。每個音符被計為容差內、超過三個範圍之一，或未配對。未配對的生成音符留在分母中，因此新增離格音符會降低容差內比例。此量沒有參照音符 recall 項，因此刪除未配對的生成音符可能提高比例；我們把它與音符數和同難度密度一併解讀。分析先對每張譜摘要，再跨譜報告中位數與尾部。

共同平移 δ 不會改變任何相鄰音符間隔：

$$(t_{i+1} + \delta) - (t_i + \delta) = t_{i+1} - t_i. \quad (2)$$

音符類型也不變，因此以這些間隔與類型為基礎的只讀譜面測量不變或幾乎不變。

最近格點配對可能錯過恆定平移 (圖 2)。在密格線上，每個被平移的音符可能只是與另一個鄰近格點配對，因此我們改對整張譜估計單一偏移。令 G_k 表示固定的小節、拍與八分音符格線，並定義 $d(x, G_k) = \min_{g \in G_k} |x - g|$ 。對音符時間 t_i ，候選平移的分數為

$$S(\delta) = \sum_k w_k \frac{1}{n} \sum_i \left[1 - \frac{d(t_i - \delta, G_k)}{\tau} \right]_+, \quad (3)$$

$$\hat{\delta} = \arg \max_{\delta \in [-250, 250] \text{ ms}} S(\delta),$$

其中 $[z]_+ = \max(z, 0)$ 、 $\tau = 12 \text{ ms}$ ，小節、拍與八分音符格線的權重依序為 0.2、0.3 與 0.5。搜尋間隔為 0.5 ms。作者編定格線來自官方譜面的時值圖，而非其音符序列；音訊估計格線則由音訊 downbeat 推估。合併三種格線可消解多數週期性平手；近似乎手時，取幅度最小的偏移。兩種時值摘要都必須有上述其中一種外部格線；作者編定時值圖與音訊估計格線皆不

可得時，時值結果記為不可用。BPM 只提供週期、不提供相位，因此不足以作為時值參照。

3.5 受控擾動與判定準則

發展組反應矩陣屬描述性分析。它報告最大劑量的標準化變化，以及逐譜淨方向：相對各自原譜上升的譜面比例減去下降比例。完整的發展組計算與 C5 的獨立 LM 檢查見附錄 A。

我們在 80 個留出歌曲群組上評估十列預先指定的擾動-測量配對。五個確定性擾動複本先在每張譜、每個劑量內平均，各 course 再於歌曲內平均，因此歌曲是推論單位。每項檢驗使用定向後的劑量相關，以及最大劑量減 sham 對比。我們計算歌曲群組 bootstrap 區間，並對十列套用 Bonferroni 校正的 99.5% 區間。若至少 72 首歌曲可評、所有必要控制均通過，且兩個調整後上界皆低於零，該反應即符合準則。完整協定見附錄 A。

各項控制與對應測量家族所主張的不變性一致，包括精確重算、音符與格線共同平移、時值與密度測量使用的 Don-Ka 音色雙射，以及只讀譜面測量使用的整譜平移。必要控制若未通過，該目標反應便不能計為受到支持。

3.6 受評系統

我們評估五個公開生成器，涵蓋三種音符格式：太鼓音符類型、僅含時值的 onset 串流，以及 osu! 位置型物件。兩個系統產生太鼓音符類型：Mapperator v32 [17] 是社群開發、採 MIT 授權的多模式 osu! beatmap 生成框架，本研究以 taiko 模式評估；另一個是 FDG 發表的 TaikoNation [2]，本研究直接執行作者公開的研究 repository。另外三個系統只進入時值與音樂呼應測量：Dance Dance Convolution 的 onset 管線 (ddconset) [1]、GenéLive! 的公開 timing-only 配置 [3]，以及以 osu! 難度為目標的生成器 AutoOsu [18]。全部系統都在其公開推論配置下，從音訊為同一批 40 首發展歌曲製譜。本研究未在此語料上訓練或微調這些系統，但這些商業歌曲與各系統訓練資料的重疊無法排除 (§6)。course 對映如下：Mapperator 使用相應的太鼓 course；GenéLive 的 Beginner、Easy、Medium、Hard、Challenge 設定分別對映到 Easy、Normal、Hard、Oni、Ura，歌曲無 Ura 譜時，Challenge 以 Oni 為參照 course；單一設定系統則使用指定的 Oni 參照。同一音符格式共用轉換至評估事件串流的程序 (§4.5)。同批歌曲的人類譜提供參照列。依難度生成的系統對每個可得 course 各產生一張譜 (170 或 200 張)；其餘系統每首歌產生一張 (40 張)。我們將這些剖面報告為描述性的發展組分析。

4 結果

4.1 九項有效檢驗符合留出準則

十列預先指定的配對皆符合兩項反應準則，32 項適用的控制檢查全數通過，而且每項分析都保留 80 個歌曲群組 (表 3)。兩列 C5 在代數上等價，因此結果代表橫跨七個有效輸出軸的九組非冗餘擾動-測量配對。

32 項控制皆精確維持不變。C1s 保留 332 個完整 course，C8 保留 330 個，其餘配對各保留 333 個。樣本數與排除原因見附錄 A。

C5 只提供一個有效軸。重複 4-gram rate 正好等於一減 unique 4-gram rate，因此兩者的鏡像對稱範圍分數，除浮點捨入誤差外完全相同。預先指定的兩個 C5 輸出名稱不能視為彼此獨立的佐證；C5 支持的是單一有效 4-gram 重複 / 唯一性反應。

4.2 外部時間可偵測譜面-音訊平移

一張譜的密度、模式與音符類型可以看似合理，同時相對音樂偏晚。C2 將每個音符平移 15、30 或 60 ms。在發展組上，沒有任何主要只讀譜面輸出的變化超過人類標準差的 0.03 倍，因為只看間隔與類型的測量對共同平移保持不變。

最近格點配對也會錯過平移：密格線可能把每個被平移的音符配到另一個鄰近細分點。兩種參照來源的格線相位偏移搜尋，都回傳 15.00、30.00 與 60.00 ms 的中位估計。每個來源、每個平移量下，至少 169/170 張譜落在注入值的 3 ms 內。連打首音 onset 支持度也會在音符 onset 處作出反應 (各強度淨方向 -0.74 至 -0.88)，並在音符時間保留時保持不變。密集時值抖動下，每張譜在每個強度的 6 ms 內音符比例都下降；在 ± 10 ms 時，容差外比例的實測中位數為 0.40，符合 $P(|U(-10, 10)| > 6) = 0.4$ 。

稀疏錯誤需要尾部敏感的讀數。在 C1s 下，最近格點會重新配對多數被移動音符，因此平均時值誤差的跨譜中位數維持為零。時值誤差 p99 在留出檢驗中作出反應；音符序列 LM 也會改變，因為移動一個音符會改變兩個相鄰間隔。密度實質不變，形式則只有微弱反應。

4.3 目標擾動揭露代理量的有利移動

兩個借用的指標，在目標擾動下朝名目上較有利的方向移動 (圖 3 左)。*Perplexity* 偏好常見模式：發展組人類譜的平均值為 9.44；向 LM 最常見模式改寫後，perplexity 下降 37% ($9.44 \rightarrow 5.98$)。Dance Dance Convolution 把 perplexity 作為留出人類譜上的模型適配度 [1]；若將它移植為生成結果的無參照品質讀數，「越低越好」的解讀便會偏好改寫後的譜面。這是似然 / 品質背離在譜面層級的實例 [19]。一個 LM 產生改寫、另一個 LM 評分時，反轉仍然存在 ($9.44 \rightarrow 6.04$ ， -36%)。pattern-IC 範圍分數隨三個劑量上升並移向人類範圍。在留出次要分析中，其最大劑量變化為 $+0.021$ ，nominal 95% 區間為 $[-0.034, 0.077]$ ；原始 trigram NLL 則從 2.087 降至 1.715 (-0.373 ， $[-0.399, -0.346]$)。因此，典型性本身無法修正此案例。有效 4-gram 軸 (§4.1) 在發展組上從 0.99 降至 0.87。

自相似度偏好崩解：以譜面自身最主要的 4-gram 循環取代原譜，使自相似結構度 [9] 上升 62% ($0.0848 \rightarrow 0.1370$)，集合層級 Self-BLEU [6] 則從 0.845 上升至 0.898。複製貼上的輸出依構造會更加自相似，但 4-gram 重複 / 唯一性分數從 0.99 降至 0.83。

另外兩項觀察結果補足論證。方向不穩定：對 §4.5 兩個公開可得、輸出位於人類語料高 entropy 側的太鼓生成器，perplexity 以預期方向區分人類與生成譜 (AUC 0.80)；但 C5 顯示相同讀法在低 entropy 側會反轉。若帶號品質指標的方向取決於系統位在人類分佈的哪一側，它便無法支持穩定排名；同難度範圍分數把兩側一致解讀為偏離典型性。C5 顯示該分數為何必須與 4-gram 重複 / 唯一性軸一併閱讀。譜長混




圖 2: 為何時值需要整譜估計。左: 最近格點配對可能把平移後的音符配到不同細分點, 因而報出很小的局部誤差。右: 我們測試候選的整譜偏移; 圖中的示意一致性曲線最高點位於注入的 +60 ms 平移。格線在評估生成譜面之前即已固定。

受控擾動 (強度)	改變的性質	預先指定的反應
C1 時值抖動 ($\pm 10/20/30$ ms)	音符時值	時值容差內比例 $\downarrow$
C1s 稀疏時值錯誤 (名目 0.5/1/2%, ± 60 ms)	少數音符時間	絕對時值誤差 p99 $\uparrow$
C2 整體平移 (+15/30/60 ms)	譜面-音訊對齊	絕對格線相位偏移 $\uparrow$
C3 音符類型置換 ($p=0.2/0.4/0.8$)	局部轉移	轉移熟悉度 $\downarrow$
C4 循環崩解 ($p=0.3/0.6/1$)	重複與形式	4-gram 典型性 $\downarrow$
C5 常見模式改寫 ($p=0.3/0.6/1$)	模式多樣性	4-gram 典型性 $\downarrow$ (單一有效軸)
C6 音符率縮放 ($\times 0.5/1.5/2$)	難度適配	音符率典型性 $\downarrow$
C7 爆發插入 (2/4/8 個叢集)	局部過載	密度尖峰限制 $\downarrow$
C8 小節順序洗牌 ($p=0.3/0.6/1$)	全局形式	4-gram 典型性 $\downarrow$

表 2: 受控擾動及其九項非冗餘目標讀數。C3–C5 保留音符時間, C4 與 C6 則保留或控制密度。C5 原先具名的兩個 4-gram 輸出在代數上等價, 因此只計為一個有效軸。pattern-IC 典型性與原始 trigram NLL 保留為不預設方向的次要分析。附錄 B 提供視覺化前後比較與完整轉換規格。

配對	主要反應	Courses	$\bar{\rho}_{\text{dose}}$ [99.5% CI]	$\bar{\Delta}_{\text{max}} - \text{sham}$ [99.5% CI]
C1	時值容差內比例	333	-.744 [-.815, -.667]	-.502 [-.558, -.446]
C1s	絕對時值誤差 p99	332	-.234 [-.344, -.134]	-.306 [-.508, -.144] ms
C2	絕對格線相位偏移	333	-.916 [-.981, -.826]	-55.58 [-61.43, -49.83] ms
C3	轉移熟悉度	333	-.800 [-.856, -.737]	-.231 [-.262, -.199]
C4	4-gram 典型性	333	-.445 [-.573, -.312]	-.165 [-.226, -.108]
C5	4-gram 典型性	333	-.358 [-.459, -.258]	-.131 [-.189, -.078]
C6	音符率典型性	333	-.693 [-.784, -.579]	-.582 [-.672, -.483]
C7	密度尖峰限制	333	-.940 [-.950, -.930]	-.619 [-.644, -.593]
C8	4-gram 典型性	330	-.589 [-.728, -.435]	-.224 [-.293, -.156]

表 3: 80 個歌曲群組上的留出結果。定向後數值越大越好, 因此目標敏感度表現為負的劑量相關, 以及負的最大劑量減 sham 對比。九組有效配對皆符合預先指定的準則; 區間為家族校正的 99.5% 歌曲群組 bootstrap 區間。C5 報告兩列代數等價輸出中的一列。

淆: 在相同系統池上, type-token ratio 與音符數的相關為 $|\rho| = 0.85$, distinct-2 為 0.56, 範圍分數則至多為 0.28。

這些案例確立了互補性, 卻沒有提供聚合權重。因此, 我們讓各輸出維持分開, 不以單一總分隱藏其中的權衡。完整的指標-擾動反應矩陣見附錄中的圖 9。

4.4 本文所提元件的發展組證據

表 1 中另五項元件具有描述性的發展組證據。把原譜與三個劑量合併計算的 Spearman 反應, 支持彼此不同的操作角色。交互回應在循環崩解與小節洗牌下下降 ($\rho = -.612$ 與 $-.506$), 在時值抖動與整體平移下則幾乎不變 ($-.086$ 與 $-.003$)。停滯-疏離代理量對循

環崩解有強烈反應 (定向為越大越好後 $\rho = -.924$), 在時值抖動與整體平移下變化很小 ($-.007$ 與 $+.010$)。這些結果支持對目標結構變化的敏感度。

兩項音訊呼應測量捕捉不同時間尺度。連打首音 onset 支持度在整體平移下下降 ($\rho = -.559$); 小節層級密度-能量呼應在一致密度縮放下保持穩定 ($\rho = +.005$), 在小節洗牌下下降 ($\rho = -.386$)。它對爆發插入的反應偏弱 ($\rho = -.092$), 因此其解讀限於小節尺度共變。依難度計算的人類譜差距描述的是聯合特徵分佈: 它能標示不同於訓練點雲的特徵組合, 卻不把不尋常譜面分類為創意或品質不佳。在 C3–C8 下, 其同難度分數的最大劑量淨方向介於 $-.32$ 與 $-.88$; 整體平移下的中位變化為零。




圖 3: 一項測量錯過目標變化、另一項測量作出反應的兩個案例。長條顯示相對原譜上升的譜面比例減去下降比例；由淺至深表示發展組上的三個擾動強度（僅為描述性結果，不是把各譜視為獨立樣本的信賴敘述）。左：常見模式改寫使 LM loss 下降、pattern-IC 範圍分數上升，4-gram 重複 / 唯一性軸則往反方向移動（兩個代數等價的輸出名稱只繪一次）。右：稀疏的 ± 60 ms 時值錯誤使平均時值誤差接近零，且多被最近格點重新配對；音符序列 LM 則回應改變後的間隔。

4.5 系統剖面

圖 4 與圖 5 的描述性系統剖面分開呈現兩種會被單一數字合併的效果：相近的時值摘要比例可能源自不同時值行為，而指定 course 也可能改變只讀譜面測量的解讀。

相似的時值比例可能源自不同原因。在圖 4 中，近乎為一的人類列是以作者編定小節 metadata 作為參照的一致性檢查，不是模型結果。兩個太鼓系統落在 6 ms 內的音符中位比例幾乎相同（0.59 與 0.58），其餘時值行為卻不同：Mapperatorinator 有 10% 的相鄰間隔超出相對容差，TaikoNation 則為 41%。格線相位偏移搜尋得到 26 與 55 ms 的中位偏移；最近格點配對對兩者卻都報告不到 1 ms 的 6 ms 容差外平均誤差。TaikoNation 的譜面活動與音訊能量也幾乎無關（相關 -0.003 ），音符落在平均能量的 frame 上。DDC onset 系統在相同音訊上得到 2.5 ms 偏移，可作為共享解碼偏移的控制。與 Mapperatorinator 共用 osu! 轉換路徑的 AutoOsu 讀出 19 ms 中位偏移；不同數值排除了共同轉換常數作為唯一解釋（§3.6）。

指定 **course** 會改變讀數。Mapperatorinator 的生成 / 人類音符率比從 Easy、Normal 的 2.15–2.35，降至 Oni 的 1.31 與 Ura 的 1.07（附錄中的圖 10）。其音符率、短間隔與局部模式分數在 Easy 至 Hard 低於 0.5，在 Oni 與 Ura 則接近 1。時值沒有相同趨勢：落在 6 ms 內的中位比例依序為 0.56、0.60、0.59、0.57 與 0.62。因此，證據支持的是難度不匹配，不是高難度下的全面改善。TaikoNation 只有單一設定；在該設定下，音符率與短間隔負荷落在人類範圍，卻有 55% 的 trigrams 未見於依難度訓練的 LM，重複 4-gram rate 為 0.004。

5 討論

ChartGenEval 為譜面生成器提供可自動計算的六維度回饋。留出檢驗顯示，七個有效輸出軸會回應各自的目標變化；發展組分析也找出常用代理量的盲點。這套剖面可用來比較模型版本，並指出變化發生在哪一

個維度。具有明確方向的輸出可作為獎勵或懲罰，可玩性檢查可作為限制，描述性輸出則可作為監測訊號。強化學習可依任務選擇這些訊號並設定權重。

非典型性必須結合脈絡解讀。受控擾動顯示，目標變化往往會把分數推出同難度人類範圍，但反向推論並不成立：不尋常譜面可能反映創意選擇。時值與可行性檢查有助於解讀這項偏離。當訊號不一致時，剖面會直接呈現其中的權衡。距離尺度可協助理解大幅偏離：發展組人類譜在序列軸上的最大值為 4.8 個半範圍寬，Mapperatorinator 與 TaikoNation 的中位數則分別為 2.1 與 12。

可轉移性取決於測量角色。時值與音樂呼應測量只讀音符時間，因此可直接施用於三種音符格式。序列、形式與距離測量需要目標遊戲的 tokenizer，以及供校準的人類譜；lane、位置或方向 token 都可取代太鼓音符類型。相同的受控擾動設計可檢查哪些反應能轉移到另一款遊戲。位置型遊戲還需要移動成本、手部分配與旋轉等額外檢查。

6 限制

證據範圍。受控擾動顯示測量會對已知變化作出反應；它們不直接測量玩家體驗。九種擾動未涵蓋配錯歌曲、刪除音樂上重要的音符，以及刻意離格配置。個別譜面在擾動後也可能移向人類範圍。另五項元件只有發展組證據。最後，預先指定的兩個 C5 輸出名稱在代數上等價；未來研究應改測獨立的結構測量。

語料與系統範圍。人類範圍由單一遊戲語料定義，其難度與速度涵蓋彙整於附錄圖 6。其他音符格式只接受時值與音樂呼應測量，每個公開系統也只以一個公開配置與一個 seed 執行。發展歌曲與系統訓練語料可能重疊，本研究未加以控制。共用路徑比較顯示，單一轉換常數不足以解釋觀察到的所有偏移，但各格式特定的轉換效應仍可能存在。因此，系統結果屬比較性描述。

測量與推論。時值容差內比例會懲罰新增的離格音符，卻沒有參照 recall 項，因此刪除音符可能提高比




圖 4: 受評系統在 40 首發展歌曲上的時值，使用作者編定格線。每條顯示落在 6 ms 內、6–12、12–18、18 ms 以上或未配對的平均音符比例； n 為譜面數。右側橫線涵蓋 6 ms 內比例的第 10–90 百分位，圓點標示中位數，倒三角形標示最小值。相近的平均容差內比例，仍可能伴隨不同的時值尾部。

	Timing within 6 ms	Note rate	Short intervals	Familiar transitions	Local patterns	4-gram repetition / uniqueness	overload	density spike	playability
human reference	1.00	1.00	1.00	0.75	1.00	1.00	✓	✓	✓
Mapperatorinator	0.59	0.23	0.36	0.23	0.19	1.00	✓	✓	✗
TaikoNation	0.58	1.00	1.00	0.00	0.01	0.08	✓	✓	✓

圖 5: 人類參照與兩個使用太鼓音符類型的生成器，在發展組上的分開結果。第一欄是音符落在格線 6 ms 內的中位比例；其餘格為 $[0, 1]$ 的校準分數。音符率、短間隔、局部模式與 4-gram 重複 / 唯一性各欄的 1 表示中位數落在人類範圍；轉移熟悉度是單側分數（越大越好），連人類參照也只有 0.75，因為 LM 仍會遇到未見的 trigrams。右側符號以中位閾值 0.5 分開顯示過載、尖峰與可玩性檢查。其他音符格式只出現在時值比較（圖 4）。各欄揭露不同偏離，不合成總分。

例；這項測量也需要外部格線。留出時值結果使用作者編定格線，音訊估計替代方案則只有發展組證據。序列 token 包含音符間隔，因此時值與序列反應可能重疊（附錄中的圖 9）。各 course 先在歌曲內平均，因此歌曲是推論單位。確定性的擾動複本在譜內平均，不會形成額外樣本。

7 結論

我們提出 ChartGenEval，一套六維度指標套件。它以配對官方譜面作為作者編定的時值圖，同時排除其中的音符位置，不把它們當成目標。時值與另外五個較

高層次維度並列報告；原始描述、雙側典型性與單側可行性檢查保留各自角色，不合成整體分數。

九組非冗餘擾動–測量配對，在 80 個歌曲群組上皆符合留出敏感度與不變性準則。同一研究顯示，只讀譜面測量會錯過整體平移，perplexity 與自相似度則可能在目標擾動下朝名目上有利的方向移動。

這套剖面提供自動化回饋，可用來比較與迭代譜面生成器。具有明確方向的輸出可引導以獎勵為基礎的最佳化，可行性檢查可作為限制，描述性輸出則可追蹤模型行為。這種依角色使用訊號的設計可支援強化學習，同時讓各維度維持分開。

倫理聲明

本研究使用 §3.2 所述、自網路來源蒐集的社群轉錄譜面與對應音訊；這些可能受版權保護的材料不隨本文再散布。釋出材料不包含原始譜面、音訊、個人資料或譜面生成器。更強的評估能力可能降低大量自動產製內容的成本，因此高量部署仍需搭配平台政策與審核機制。

AI 使用聲明

AI 助理在作者指導下用於實驗編排、起草與編輯；所有報告數值均由作者查核。

A 語料涵蓋與留出評估協定

A.1 語料涵蓋範圍

校準語料依 course、星級與速度彙整。圖 6 呈現其難度與速度涵蓋。

A.2 資料組建構與完整性

來源紀錄依 group_id 與音訊 SHA-256 正規化；不一致的別名會在資料組索引前排除。測試集依儲存順序包含 120 個歌曲群組，其中第 0–39 組構成發展組，第 40–119 組構成留出組。在檢視留出結果前，我們先固定資料集版本、擾動與劑量、目標測量、控制、閾值、校準與分析計畫。

A.3 複本、完整性與推論單位

每個非零擾動 cell 與控制條件都使用五個固定的 base seed。複本先在每張譜、每個劑量內平均。course 只有在原譜值、所有目標劑量與複本、指定的 sham 及必要控制皆可時才算完整。歌曲至少有一個完整 course 才進入該檢驗；完整 course 再於歌曲內平均。因此，兩個反應統計量的推論單位都是歌曲，而非譜面、course 或複本。確定性的 no-op 與缺失 cell 不進入分析。

A.4 控制檢查與數值不變性

每項保留測量都進行 identity 重算。音符、作者編定格線與時長共同平移 +1 秒，用於檢查對時間原點的不變性。Don-Ka 音色雙射只用於與音色無關的時值與密度測量，不作為 grammar 或形式的控制。60 ms 的 C2 平移則是只讀譜面密度、grammar 與結構測量的 sham。必要控制未通過時，對應目標反應便不能視為受到支持。每項測量均採用指定的等價容差與 timestamp 捨入規則。只讀譜面的間隔運算使用整數微秒，比最小報告容差細三個數量級。

A.5 區間與判定規則

把輸出定向為越大越好後，第一個統計量是原譜加三個劑量的四種強度，與測量之間的逐譜 Spearman 相關；四個反應全為常數時，敏感度定義為零。第二個統計量是定向後的最大劑量值減去指定的 sham。點估計取歌曲層級值的平均。我們進行 10,000 次歌曲群組 bootstrap：次要分析報告 nominal 95% 區間，十列主要配對則使用 Bonferroni 校正的 99.5% 區間。若至少 72/80 首歌曲可評、所有控制均通過，且兩個調整

後上界皆低於零，該反應即獲支持。調整後下界若為非負，則與預期反應相反；其餘情況視為無法判定。兩列 C5 輸出必須共同符合規則，但其代數等價性只留下單一有效軸。C5 LM 使用完整且依儲存順序排列的訓練集、trigram order 3，以及 $\text{add-}\alpha = 0.05$ 。

A.6 樣本數與排除

留出分析從 333 張譜產生 50,283 筆觀察紀錄。C1s 保留 332 個完整 course，C8 保留 330 個，其餘有效配對皆保留 333 個。32 項控制全數通過，觀察到的最大絕對差異為零。另有 19 個確定性 no-op cell 遭排除。




圖 6: 定義校準範圍的人類參照語料之 course 難度與速度涵蓋。(a) 3,880 張訓練譜中，各 course 的星級計數：每個 course 都橫跨寬廣且逐步位移的難度範圍。(b) 速度直方圖（中位 170 BPM，範圍 65-376）。

B 受控擾動規格

圖 7 呈現各項擾動所施加的操作性變化，以及預先指定的目標測量。

170 張譜的發展矩陣在每個非零 cell 使用一個 realization，連同原譜共產生 4,760 張變體。C1s 將譜面 n 個音符中的 $\max(1, \text{round}(np))$ 個平移 ± 60 ms。C3-C5 保留音符時間，C4 與 C6 則保留或控制密度。原始特徵與其衍生分數都在同一批變體上計算，等價量只計一次。C5 由一個 LM 選擇常見模式改寫，再由另一個獨立擬合的 LM 評分；perplexity 反轉仍然存在（9.44 $\rightarrow$ 6.04，-36%）。



圖 7: 受控擾動圖譜。藍色表示原譜，橘色表示編輯後的事件。各 panel 呈現一種擾動所改變的性質，並標示其目標測量。C1–C2 針對時值，C3 針對轉移熟悉度，C4–C5 與 C8 針對重複或形式，C6–C7 則針對難度適配與局部負荷。這些編輯隔離了操作性變化，但不涵蓋譜面品質的所有面向。

C 指標指南與延伸結果

圖 8 將各構念連結至所需輸入、代表性輸出與目前最強的證據；其中的證據標籤區分具留出擾動檢驗的輸出，以及由發展組分析支持的元件。

圖 9 顯示目標擾動可能同時影響多個分數家族，因此這些測量應以剖面方式解讀，而非視為彼此可交換的孤立讀數。



圖 8: 指標與構念對照指南。每個 panel 提出一項評估問題，圖示相關訊號，列出代表性輸出，並標示目前最強的證據。「留出子集」表示只有表 1 中具名的輸出具有留出擾動證據。典型性描述相對同難度人類範圍的偏離。




圖 9: 14 個非冗餘的校準後只讀譜面分數，對各擾動在發展組最大強度下的反應。各格涵蓋範圍典型性分數與單側檢查。紅色表示分數下降、藍色表示上升；數值以人類參照譜的標準差為單位，截斷於 ± 4 。黑框標示在發展組選出的目標列，不代表統計顯著性。矩陣同時顯示目標敏感度與跨家族耦合。




圖 10: Mapperatorinator 在配對發展譜上的探索性難度剖面。Easy 至 Oni 各含 40 個歌曲–course 配對，Ura 含 10 個。點為中位數，豎線跨第 10 至 90 百分位。生成密度會隨 course 難度提高而接近人類參照，時值卻沒有相同趨勢；這支持 course 不匹配的解讀，而非高難度下的全面改善。

D 釋出材料

程式碼、評估紀錄與繪圖程式公開於 <https://github.com/JacobLinCool/ChartGenEval>。

參考文獻

- [1] C. Donahue, Z. C. Lipton, and J. McAuley, “Dance dance convolution,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, D. Precup and Y. W. Teh, Eds., vol. 70. Sydney, Australia: PMLR, Aug. 2017, pp. 1039–1048. [Online]. Available: <https://proceedings.mlr.press/v70/donahue17a.html>
- [2] E. Halina and M. Guzdial, “TaikoNation: Patterning-focused chart generation for rhythm action games,” in *The 16th International Conference on the Foundations of Digital Games (FDG) 2021*, ser. FDG ’21. New York, NY, USA: Association for Computing Machinery, Aug. 2021, pp. 1–10. [Online]. Available: <https://doi.org/10.1145/3472538.3472589>
- [3] A. Takada, D. Yamazaki, Y. Yoshida, N. Ganbat, T. Shimotomai, N. Hamada, L. Liu, T. Yamamoto, and D. Sakurai, “Genélive! generating rhythm actions in Love Live!” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 4, pp. 5266–5275, Jun. 2023. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/25657>
- [4] J. Hanzen, E. Halina, and M. Guzdial, “Time-based chart partitioning: Improving local coherency in rhythm game chart generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 21, no. 1, pp. 43–51, Nov. 2025. [Online]. Available: <https://ojs.aaai.org/index.php/AIIDE/article/view/36808>
- [5] J. Li, M. Galley, C. Brockett, J. Gao, and B. Dolan, “A diversity-promoting objective function for neural conversation models,” in *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, K. Knight, A. Nenkova, and O. Rambow, Eds. San Diego, California: Association for Computational Linguistics, Jun. 2016, pp. 110–119. [Online]. Available: <https://aclanthology.org/N16-1014/>
- [6] Y. Zhu, S. Lu, L. Zheng, J. Guo, W. Zhang, J. Wang, and Y. Yu, “Txygen: A benchmarking platform for text generation models,” in *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, ser. SIGIR ’18. New York, NY, USA: Association for Computing Machinery, Jun. 2018, pp. 1097–1100. [Online]. Available: <https://doi.org/10.1145/3209978.3210080>
- [7] L.-C. Yang and A. Lerch, “On the evaluation of generative models in music,” *Neural Computing and Applications*, vol. 32, no. 9, pp. 4773–4784, 2020. [Online]. Available: <https://doi.org/10.1007/s00521-018-3849-7>
- [8] H.-W. Dong, K. Chen, J. McAuley, and T. Berg-Kirkpatrick, “MusPy: A toolkit for symbolic music

- generation,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 101–108. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000187.pdf>
- [9] S.-L. Wu and Y.-H. Yang, “The jazz transformer on the front line: Exploring the shortcomings of AI-composed music through quantitative measures,” in *Proceedings of the 21st International Society for Music Information Retrieval Conference (ISMIR 2020)*, Montréal, Canada, 2020, pp. 142–149. [Online]. Available: <https://archives.ismir.net/ismir2020/paper/000339.pdf>
- [10] M. Gover and O. Zewi, “Music translation: Generating piano arrangements in different playing levels,” in *Proceedings of the 23rd International Society for Music Information Retrieval Conference (ISMIR 2022)*, Bengaluru, India, Dec. 2022, pp. 36–43. [Online]. Available: <https://archives.ismir.net/ismir2022/paper/000003.pdf>
- [11] J. Wang, W. Huang, and X. Li, “Mania archetype: Chart generation for rhythm action games with human factors,” in *Human Factors in Virtual Environments and Game Design*, vol. 137. AHFE Open Access, 2024, pp. 175–185. [Online]. Available: <https://doi.org/10.54941/ahfe1005000>
- [12] M. Plasser, S. Peter, and G. Widmer, “Discrete diffusion probabilistic models for symbolic music generation,” in *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*. International Joint Conferences on Artificial Intelligence Organization, Aug. 2023, pp. 5842–5850. [Online]. Available: <https://www.ijcai.org/proceedings/2023/648>
- [13] J. Retkowski, J. Stępnik, and M. Modrzejewski, “Fréchet music distance: A metric for generative symbolic music evaluation,” *arXiv preprint arXiv:2412.07948*, Jan. 2025. [Online]. Available: <https://arxiv.org/abs/2412.07948>
- [14] J. Opria, “STRUM: A spectral transcription and rhythm understanding model for end-to-end generation of playable rhythm-game charts,” *arXiv preprint arXiv:2605.12135*, May 2026. [Online]. Available: <https://arxiv.org/abs/2605.12135>
- [15] A. Friberg and J. Sundberg, “Time discrimination in a monotonic, isochronous sequence,” *The Journal of the Acoustical Society of America*, vol. 98, no. 5, pp. 2524–2531, Nov. 1995. [Online]. Available: <https://doi.org/10.1121/1.413218>
- [16] J. London, *Hearing in Time: Psychological Aspects of Musical Meter*, 2nd ed. Oxford University Press, May 2012. [Online]. Available: <https://academic.oup.com/book/9899>
- [17] O. Schipper, “Mapperatorinator: An AI framework for generating and moddingosu! beatmaps for all gamemodes from spectrogram inputs,” GitHub repository, May 2026, version 32.0.0; MIT-licensed software release. [Online]. Available: <https://github.com/OliBomby/Mapperatorinator/releases/tag/v32.0.0>
- [18] S. Lee and D. Jeong, “AutoOsu: Audio-aware action generation for rhythm games,” Late-Breaking Demo at ISMIR 2023, 2023, project page: <https://issyun.github.io/autoosu/>; public source repository: <https://github.com/issyun/AutoOsu>. [Online]. Available: https://ismir2023program.ismir.net/lbd_319.html
- [19] L. Theis, A. van den Oord, and M. Bethge, “A note on the evaluation of generative models,” in *4th International Conference on Learning Representations (ICLR 2016), Conference Track Proceedings*, San Juan, Puerto Rico, May 2016. [Online]. Available: <https://arxiv.org/abs/1511.01844>